

UNIVERZA V LJUBLJANI
FAKULTETA ZA RAČUNALNIŠTVO IN INFORMATIKO

Nik Katanović Leban

**Prototip spletne aplikacije za prodajo
vozil z ocenjevanjem njihove vrednosti**

DIPLOMSKO DELO

VISOKOŠOLSKI STROKOVNI ŠTUDIJSKI PROGRAM
PRVE STOPNJE

MENTOR: viš. pred. dr. Igor Rožanc

Ljubljana, 2026

To delo je ponujeno pod licenco *Creative Commons Priznanje avtorstva-Deljenje pod enakimi pogoji 2.5 Slovenija* (ali novejšo različico). To pomeni, da se tako besedilo, slike, grafi in druge sestavine dela kot tudi rezultati diplomskega dela lahko prosto distribuirajo, reproducirajo, uporabljajo, priobčujejo javnosti in predelujejo, pod pogojem, da se jasno in vidno navede avtorja in naslov tega dela in da se v primeru spremembe, preoblikovanja ali uporabe tega dela v svojem delu, lahko distribuira predelava le pod licenco, ki je enaka tej. Podrobnosti licence so dostopne na spletni strani creativecommons.si ali na Inštitutu za intelektualno lastnino, Streliška 1, 1000 Ljubljana.



Izvorna koda diplomskega dela, njeni rezultati in v ta namen razvita programska oprema je ponujena pod licenco GNU General Public License, različica 3 (ali novejša). To pomeni, da se lahko prosto distribuira in/ali predeluje pod njenimi pogoji. Podrobnosti licence so dostopne na spletni strani <http://www.gnu.org/licenses/>.

Besedilo je oblikovano z urejevalnikom besedil $\text{\LaTeX}$.

Kandidat: Nik Katanović Leban

Naslov: Prototip spletne aplikacije za prodajo vozil z ocenjevanjem njihove vrednosti

Vrsta naloge: Diplomaska naloga na visokošolskem programu prve stopnje Računalništvo in informatika

Mentor: viš. pred. dr. Igor Rožanc

Opis:

V diplomskem delu zasnujete prototip spletne aplikacije za prodajo vozil z vključeno samodejno oceno tržne vrednosti vozil na podlagi primerljivih oglasov na spletu. V ta namen preučite obstoječe rešitve, opredelite zahteve in zasnujete aplikacijo, pri čemer posebno pozornost namenite učinkovitemu vrednotenju vozil. Z uporabo ustreznih tehnologij implementirajte delujoč prototip ter ga ustrezno analizirajte in ovrednotite.

Title: Prototype of a web application for selling vehicles with vehicle valuation

Description:

In the thesis, design a prototype of a web application for vehicle sales with integrated automated market value estimation based on comparable online listings. For this purpose, examine existing solutions, specify the requirements, and design the application, with a special focus on effective vehicle valuation. Implement a working prototype using appropriate technologies, then analyze and evaluate it accordingly.

Rad bi se zahvalil svojemu mentorju Igorju Rožancu, za vso aktivno pomoč in svetovanje pri razvoju te diplomske naloge. Zahvalil bi se tudi vsem sodelavcem iz podjetja CargoX, ki so z mano delili svoje znanje in izkušnje, ter mi omogočili, da sem se lahko lotil tako zahtevnega projekta. Posebna zahvala gre moji družini, ki me je ves čas podpirala in mi stala ob strani.

Kazalo

Povzetek

Abstract

1	Uvod	1
2	Sorodne rešitve	3
3	Ozadje	9
3.1	Oglas in atributi vozila	9
3.2	Zajem podatkov iz spletnih virov	11
4	Razvoj rešitve	15
4.1	Zahteve	15
4.2	Arhitektura rešitve	18
4.3	Uporabne tehnologije	19
4.4	Načrtovanje podatkovne baze	22
4.5	Arhitektura zalednega sistema	25
4.6	Arhitektura uporabniškega vmesnika	29
4.7	Sistem za vrednotenje vozil	33
4.8	Infrastruktura in avtomatizacija	40
5	Analiza in vrednotenje rešitve	45
5.1	Raziskovalna vprašanja in merila uspešnosti	45
5.2	Metodologija in merilno okolje	46

5.3	Uporabljene mere	47
5.4	Značilnosti zbranih podatkov	49
5.5	Natančnost ocene vrednosti	53
5.6	Občutljivost algoritma na parametre	59
5.7	Latenca posameznega vrednotenja	62
5.8	Obnašanje pod obremenitvijo	64
5.9	Preverjanje funkcionalnih zahtev	66
5.10	Preverjanje nefunkcionalnih zahtev	67
5.11	Uporabniški preizkus	68
5.12	Simulacija uporabe	69
5.13	Grožnje veljavnosti	72
5.14	Povzetek ugotovitev	73
6	Sklep	75
	Literatura	79
	Članki v revijah	79
	Članki v zbornikih konferenc	81
	Ostala literatura	82
	Dodatek	89

Povzetek

Naslov: Prototip spletne aplikacije za prodajo vozil z ocenjevanjem njihove vrednosti

Avtor: Nik Katanović Leban

Diplomsko delo obravnava problem določanja ustrezne tržne vrednosti rabljenega vozila, pri prodaji ali nakupu vozila, zaradi nezadostnega pregleda stanja na trgu, stranke težko ocenijo primernost ponujene cene in vozilo kupijo po previsoki ceni ali ga prodajo pod njegovo tržno vrednostjo. Zato smo razvili prototip spletne aplikacije za objavo in pregled oglasov vozil, ki uporabnikom omogoča enostavno in varno prodajo ter nakup vozil. Ključen del predlagane rešitve je sistem za avtomatsko ocenjevanje vrednosti vozil, ki temelji na zbiranju podatkov iz zunanjih virov, njihovi normalizaciji in primerjavi vozila s podobnimi vozili na trgu. Pri oceni vrednosti se upoštevajo ključne lastnosti vozila, kot so znamka, model, letnik in prevoženi kilometri. Za pridobivanje podatkov so bili uporabljeni javno dostopni podatkovni viri ter postopki samodejnega zajema podatkov s spletnih strani za prodajo vozil. Zbrane podatke sistem obdela in uporabi za izračun ocenjene tržne vrednosti vozila. Rezultat diplomskega dela je delujoč prototip spletne aplikacije za prodajo vozil s podporo za samodejno vrednotenje vozil, razvit z uporabo tehnologij React [51], TypeScript [53], Node.js [59], Express.js [12], Python [65], PostgreSQL [77], Redis [69] in Docker [16].

Ključne besede: spletna aplikacija, vozila, vrednotenje, React, Express.js, Node.js, PostgreSQL, Docker.

Abstract

Title: Prototype of a web application for selling vehicles with vehicle valuation

Author: Nik Katanović Leban

This thesis addresses the problem of determining the appropriate market value of a used vehicle. When selling or buying a vehicle, customers have an insufficient overview of the situation on the market, so they find it difficult to assess whether the offered price is reasonable and end up buying a vehicle at too high a price or selling it below its market value. We therefore developed a prototype of a web application for publishing and browsing vehicle listings, which enables users to sell and buy vehicles simply and safely. A key part of the proposed solution is a system for automatic vehicle valuation, based on collecting data from external sources, normalising it, and comparing a vehicle with similar vehicles on the market. The valuation takes into account key vehicle characteristics such as make, model, year, and mileage. Publicly available data sources and automated data collection from vehicle sales websites were used to obtain the data. The system processes the collected data and uses it to compute the estimated market value of a vehicle. The result of the thesis is a working prototype of a web application for selling vehicles with support for automatic vehicle valuation, developed using the technologies React [51], TypeScript [53], Node.js [59], Express.js [12], Python [65], PostgreSQL [77], Redis [69], and Docker [16].

Keywords: web application, vehicles, valuation, React, Express.js, Node.js, PostgreSQL, Docker.

Poglavje 1

Uvod

Nakup in prodaja rabljenih vozil predstavljata pomemben del trga rabljenih vozil. Pri tem se kupci in prodajalci pogosto srečujejo s težavo določanja primerne tržne vrednosti vozila, saj nimajo zadostnega pregleda nad trenutno ponudbo in gibanjem cen na trgu. Raznolikost informacij je še posebej izrazita, ker je vsako vozilo unikatno glede na svoje stanje, opremo in zgodovino uporabe [26, 21].

Najpogostejši pristop k oceni vrednosti je zato primerjava primerljivih prodaj podobnih vozil iz obstoječih oglasov, vendar je samostojno izvajanje takšne primerjave časovno potratno in nezanesljivo. Oglasi lahko vsebujejo nerealno visoke ali nizke cene, uporabniki pa pogosto nimajo dovolj znanja in izkušenj, zato lahko vozilo prodajo pod njegovo tržno vrednostjo ali pa ga kupijo po previsoki ceni.

Na trgu že obstajajo rešitve za ocenjevanje vrednosti vozil, vendar so mnoge plačljive, prilagojene tujim trgom ali pa temeljijo na zastarelih podatkih, zaradi česar njihove ocene pogosto ne odražajo dejanskega stanja na slovenskem trgu rabljenih vozil.

Cilj diplomskega dela je razvoj prototipa spletne aplikacije za objavo in pregled oglasov vozil, ki vsebuje tudi sistem za samodejno ocenjevanje vrednosti vozil. Sistem temelji na zbiranju podatkov iz zunanjih virov, njihovi normalizaciji in analizi primerljivih vozil na trgu [47]. Pri določanju ocenjene

vrednosti se upoštevajo ključne lastnosti vozila, kot so znamka, model, letnik prve registracije in število prevoženih kilometrov. Dolgoročni cilj sistema je privabiti zadostno število uporabnikov, da na platformi objavijo lastne oglase vozil, s čemer bo potreba po podatkih iz zunanjih virov postopno upadla, tržno vrednost vozil pa bo mogoče ocenjevati na podlagi preverjenih oglasov, ki so zbrani znotraj platforme same.

Na začetku diplomskega dela si zastavljamo izhodišče, da je mogoče s pomočjo zbranih tržnih podatkov in primerjalne analize podobnih vozil uporabniku ponuditi uporabno in dovolj natančno oceno tržne vrednosti vozila. Pri tem želimo preveriti, ali vključitev takšnega sistema v prototip izboljša uporabniško izkušnjo pri nakupu in prodaji vozil.

Preostanek diplomskega dela je organiziran na naslednji način. Poglavje 2 predstavi podobne rešitve za prodajo in vrednotenje vozil. Poglavje 3 podrobneje predstavi oglaševanje vozil, na katerem temelji razvita rešitev, in postopke zajema podatkov s spletnih virov. Poglavje 4 je jedro naše rešitve in opiše opredelitev zahtev, načrtovanje podatkovne baze in arhitekture sistema, implementacijo zalednega in odjemalskega dela aplikacije, delovanje algoritma za vrednotenje vozil ter infrastrukturo in avtomatizacijo namestitve. V poglavju 5 je rešitev analizirana, diplomsko delo pa se zaključi s povzetkom doseženih rezultatov, kritično presojo omejitev rešitve in smeri za nadaljnje izboljšave.

Poglavje 2

Sorodne rešitve

Na področju prodaje rabljenih vozil obstaja več spletnih aplikacij, ki uporabnikom omogočajo objavo in pregled oglasov vozil. Pokaže pa se, da imajo le nekatere možnost vrednotenja vozil, od teh je večina je plačljivih. Med najbolj znanimi tujimi ponudniki sta **mobile.de** [54] in **AutoScout24** [3], ki združujeta veliko število oglasov iz različnih držav ter uporabnikom omogočata filtriranje vozil po številnih kriterijih. Poleg njiju obstaja še vrsta drugih platform, ki uporabnikom bodisi zgolj omogočajo prodajo vozil bodisi ponujajo oceno njihove vrednosti, med njimi so **AutoTrader** [2], **La Centrale** [45], **Otomoto** [61], **Cars.com** [10] in **Kelley Blue Book** [41]. Za slovenski trg je najbolj razširjena platforma **AvtoNet** [4], ki predstavlja naše osrednje mesto za objavo in iskanje rabljenih vozil. Poleg aplikacij obstajajo tudi specializirane storitve za vrednotenje vozil, najbolj znani sta **Eurotax** [21] in **CARFAX** [9].

Platforma **AvtoNet** [4] je izšla leta 1997 in danes velja za prevladujočo aplikacijo za prodajo vozil na slovenskem trgu. Uporabniku omogoča prodajo raznovrstnih vozil (kot so avtomobili, motorna kolesa in plovila). Kljub dolgi prisotnosti na trgu ni doživela večjih posodobitev, zato je njen uporabniški vmesnik zastarel in ponuja precej prostora za izboljšave. Za objavo oglasa se mora uporabnik prijaviti, medtem ko za brskanje po oglasih prijava ni potrebna. Prikaz posameznega oglasa na **AvtoNet-u** [4] je predstavljen na

sliki 2.1.

Audi A6 Avant 3.0 TDI QUATTRO-235KW-BI-TURBO-MATRIX-NAVI-S LI.. ☆



1.registracija	2015
Prevoženih	258630 km
Gorivo	diesel motor
Menjalnik	avtomatski menjalnik
Motor	2967 cm, 235 kW / 320 KM

AKCIJSKA CENA
~~18.295 €~~
16.995 €


OBKUP IN PRODAJA VOZIL


Slika 2.1: Primer oglasa na Avto.net-u

Uporabniški vmesnik je pregleden in omogoča enostavno orientacijo, zato se uporabnik na njem hitro znajde. Glavna pomanjkljivost so predvsem manjkajoče dodatne funkcionalnosti, ki bi izboljšale uporabniško izkušnjo. Dober primer je obrazec za objavo oglasa. Vneseni podatki se recimo ob prehodu na naslednji korak ne shranijo, zato mora uporabnik ob vrnitvi na prejšnji korak, ponovno vpisati celotno vsebino. Obrazec je tudi razmeroma dolg in uporabniku ne prikazuje, koliko korakov ima še do zaključka objave. Platforma sicer dela zanesljivo in zadovoljuje osnovne potrebe uporabnikov. Uporabniški vmesnik za objavo oglasa je prikazan na sliki 2.2.

The image shows a web form for posting a car advertisement on Avto.net-u. At the top, there are four tabs: 'Avto' (selected), 'Moto', 'Gospodarska vozila', and 'Mehanizacija'. Below the tabs, the heading 'Izberite osnovne podatke o vozilu' is displayed. The form contains several input fields: 'Znamka:' with a dropdown menu showing 'Izberite znamko'; 'Model:' with a dropdown menu showing 'Izberite model'; 'Karoserijska oblika:' with a dropdown menu showing 'Izberite obliko'; 'Prva registracija:' with a dropdown menu showing '-' and a year field showing '2020'; and 'Pogonsko gorivo:' with radio buttons for 'bencin', 'diesel' (selected), 'hibridni pogon', 'e-pogon', 'LPG avtoplin', and 'CNG zemeljski plin'. At the bottom, there is a large orange button labeled 'Klikni za nadaljevanje'.

Slika 2.2: Objava oglasa na Avto.net-u

Mobile.de [54] ima novejši uporabniški vmesnik, ki je bolj pregleden in omogoča enostavno navigacijo po spletnem mestu. Uporabniku omogoča da objavi oglas, brska po oglasih in filtrira vozila po različnih kriterijih. Za razliko od **AvtoNet-a** [4], **Mobile.de** [54] omogoča tudi oceno vrednosti vozila. Pri posameznih oglasih prikazuje tudi mnenje, ali je cena ugodna, primerna ali previsoka. Mnenje je predstavljeno z petstopenjsko barvno lestvico: pri ugodni ceni je lestvica obarvana z zeleno, pri previsoki rdeče, ostale stopnje pa so označene z vmesnimi barvami. Takšen pristop uporabniku omogoča hitrejše odločanje, saj mu ni treba ročno primerjati oglasov med seboj. Ocena temelji na samodejni primerjavi s podobnimi vozili v ponudbi. Pri tem pa platforma ne ponuja možnosti samostojnega vrednotenja vozila na podlagi uporabniško vnesenih podatkov, kadar oglas še ne obstaja. Prikaz osnovnih podatkov vozila z mnenjem je predstavljen na sliki 2.3.



Slika 2.3: Primer ocene vozila na Mobile.de

Specializirana storitev za vrednotenje vozil je **Eurotax** [21]. Ki se pogosto uporablja v industriji vozil, zavarovalništvu in pri trgovcih z vozili. Njegove ocene temeljijo na obsežnih zbirkah podatkov o vozilih in tržnih cenah, vendar je dostop do storitve praviloma plačljiv. Zaradi poslovnega modela in omejenega dostopa podrobna analiza delovanja sistema ni mogoča.

Na severnoameriškem trgu je najbolj razširjena tovrstna storitev **CARFAX** [9], ki poleg vrednotenja vozila ponuja tudi vpogled v njegovo celotno zgodovino. Vsako vozilo je določeno z enolično identifikacijsko številko (VIN) [37], na podlagi katere storitev pripravi poročilo o zgodovini vozila. To poročilo vključuje podatke o številu prejšnjih lastnikov, servisni zgodovini, zgodovini registracij, prijavljenih prometnih nesrečah in škodi. **CARFAX** [9] ponuja funkcijo vrednotenja vozila, ki za razliko od preprostih ocen, ki upoštevajo zgolj znamko, model in letnik, vključuje zgodovino vozila, prevožene kilometre, škodo zaradi nesreč, servisne posege ter uporabo vozila (osebna, najemniška ali komercialna raba). Vrednost se prilagaja tudi glede na regijo, saj se ponudba in povpraševanje razlikujeta po posameznih območjih. Kljub obsežni funkcionalnosti je storitev žal prilagojena za severnoameriški trg, zato ni neposredno uporabna za nas. Pregled obstoječih rešitev 2.1 je pokazal, da večina platform bodisi omogoča prodajo vozil brez naprednega sistema za vrednotenje bodisi ponuja ločene plačljive storitve za ocenjevanje vrednosti vozil. Namen naše rešitve je združiti obe funkcionalnosti v enotnem prototipu aplikacije, ki uporabnikom omogoča objavo vozil, pregled trga in samodejno oceno vrednosti vozila na podlagi obstoječih primerljivih vozil.

Tabela 2.1: Primerjava izbranih obstoječih rešitev za prodajo in vrednotenje vozil.

Rešitev	Trg	Prodaja oglasov	Ocena vrednosti vozila
mobile.de	Evropa, najbolj razširjen na nemškem trgu	Da	Osnoven prikaz cene (zeleno – ugodna, rdeče – precenjena)
AutoScout24	Evropa–Nemčija, Belgija, Italija	Da	Priporočilo cene ob objavi oglasa
Avto.net	Slovenija	Da	Nima
Eurotax	Evropa–Nemčija, Slovenija, Švica, Italija	Ne	Natančno poročilo o ceni
CARFAX	ZDA	Ne	Podrobne ocene glede na VIN

Poglavje 3

Ozadje


V tem poglavju predstavimo temeljne pojme in postopke, na katerih temelji naše delo. Najprej natančneje opišemo ključne tehnologije s tega področja, kaj je oglas rabljenega vozila in kateri atributi vozila so za nas relevantni. V nadaljevanju predstavimo še pristope za zajem podatkov, s katerimi smo pridobili gradivo za sistem vrednotenje vozil.

3.1 Oglas in atributi vozila

Oglas je vsebina, ki je namenjena predstavitvi izdelka ali storitve, ki se trži, prodaja ali kupuje [44]. Oglaševanje ima dolgo zgodovino; tiskani oglasi so se v evropskih časopisih redno pojavljali že od nekdanj, množično pa se začelo oglaševati z časopisi in revijami v 19. in 20. stoletju [78]. Z razširjenostjo interneta se je oglaševanje večinoma preneslo v elektronsko obliko, kjer danes poteka pretežni del prodaje in nakupa rabljenih vozil. V našem primeru obravnavamo spletne oglase za prodajo vozila. Vsebovati morajo vse ključne podatke. Katero vozilo se prodaja in njegove tehnične značilnosti, ki kupcu pomagajo pri odločitvi o nakupu. Poleg tega mora oglas vsebovati še tržno ceno in kontaktne podatke prodajalca. Oglas ostane objavljen na izbranem mestu, do odločitve umika ali nakupa vozila.

3.1.1 Atributi vozila

Atributi vozila ki vplivajo na ceno so njegove tehnične ali fizične lastnosti. To pa so znamka, model, izvedba (angl. *trim*), barva, opis in prostornina motorja, vrsta goriva, vrsta menjalnika, pogon (sprednji, zadnji ali štirikolesni), letnik izdelave, datum prve registracije, prevoženi kilometri, moč motorja (izražena v kilovatih ali konjskih močeh), emisijski razred, poraba goriva, tip karoserije, število vrat, število sedežev, število prestav, število lastnikov, servisna zgodovina, stanje vozila (rabljeno, novo, poškodovano), država izvora, oprema (npr. klimatska naprava, navigacija, usnjeni sedeži) in cena. V naši rešitvi se moramo omejiti, zato se osredotočimo predvsem na nekaj ključnih atributov: znamko, model, prevožene kilometre, letnik izdelave in ceno. **Znamka** in **model** služita kot identifikatorja vozila, saj na njuni podlagi vemo, za katero vozilo gre. Naslednje dva atributa sta tista, ki najbolj vplivata na razliko vrednosti med konkretnimi primeri istega modela vozila. **Prevoženi kilometri** so pomembni, ker izražajo uporabo vozila; večje kot je število prevoženih kilometrov, večja je verjetnost okvar in obrabe. **Letnik izdelave** pove starost vozila in s tem nakazuje pričakovane prihodnje stroške vzdrževanja. **Cena** je glavni podatek, saj zagotavlja primerjalno vrednost med vozili. Na sliki 3.1 prikazujemo primer oglasa v našem prototipu.



Slika 3.1: Primer oglasa na prototipu

3.2 Zajem podatkov iz spletnih virov

Spletni vir je poljubna spletna storitev ali stran, ki ponuja podatke uporabne za obdelavo, na primer oglasni portal, javna podatkovna zbirka ali programski vmesnik. Zajem podatkov iz spletnih virov predstavlja temeljni korak pri našem pristopu za vrednotenje rabljenih vozil na trgu. Obseg starosti in kakovosti zbranih podatkov neposredno vpliva na zanesljivost modelov za ocenjevanje cen [47]. V splošnem ločimo tri pristope za pridobivanje podatkov iz spleta: izkoriščanje javno dostopnih podatkovnih zbirk, dostop prek vmesnikov API-jev ter samodejni zajem podatkov s spletnih strani [47]

3.2.1 Javno dostopne podatkovne zbirke

Javno dostopne podatkovne zbirke (angl. *open datasets*) predstavljajo enega najprimernejših virov za zbiranje strukturiranih podatkov, saj so podatki v njih že organizirani, kategorizirani in pripravljeni za neposredno ana-

litično obdelavo [39]. Primeri takšnih zbirk so odprti vladni portali, (kot sta Statistični urad Republike Slovenije (SURS) [74] in Eurostat [20]), akademski repozitoriji ter portali prometnih agencij. Slabost tega pristopa je omejena razpoložljivost aktualnih tržnih podatkov. Javne zbirke običajno ne vsebujejo oglasov z aktualnimi prodajnimi cenami vozil, ki so nujno potrebni za ocenjevanje tržne vrednosti [26]. Za tuje trge sicer obstajajo javno dostopne zbirke oglasov, pridobljeni iz oglasnih portalov, (npr. nemški trg (eBay Kleinanzeigen) [60]), ki so vendar za slovenski trg takšna javna zbirka ne obstaja.

3.2.2 Dostop prek vmesnikov API

Dostop do podatkov prek vmesnika API (angl. *application programming interface*) običajno poteka tako, da se uporabnik najprej registrira pri ponudniku [29]. Ob registraciji uporabnik prejme nosilni žeton (angl. *bearer token*), ki ga mora priložiti v vsakemu zahtevku za namen avtentikacije [29]. Večina vmesnikov API je plačljivih, saj ponudniki ustvarjajo prihodek s prodajo podatkov. Brezplačni vmesniki so zato pogosto pomanjkljivi in vsebujejo zastarele podatke. V našem primeru smo vmesnike API uporabili predvsem za začetno polnitev podatkovne baze z vsemi znamkami in modeli vozil, za kar zadostujejo tudi brezplačni ponudniki.

3.2.3 Samodejni zajem podatkov s spletnih strani

Samodejni zajem podatkov s spletnih strani (angl. *web scraping*) je postopek avtomatiziranega pridobivanja strukturiranih informacij iz spletnih strani z razčlenjevanjem njihove vsebine [47]. Ta pristop se pogosto uporablja pri zbiranju oglasov za prodajo rabljenih vozil. Na voljo je veliko spletnih strani, ki vsebujejo obsežne zbirke takšnih oglasov, iz vsakega oglasa pa je mogoče pridobiti ključne strukturirane attribute vozila, (npr. znamka, model, letnik izdelave, prevoženi kilometri, vrsto goriva, tip menjalnika in navedena cena [26]). Zajem poteka z orodji za avtomatizirano brskanje po spletnih stra-

neh, (kot so Playwright [52] ali Selenium [72]), ki simulirajo obisk uporabnika, ter z razčlenjevanjem strukture dokumenta HTML za izluščitev relevantnih podatkovnih polj [47]. Problem zajema podatkov na tak način je ta, da so podatki na spletni strani namenjeni za prikaz in ne za posredovanje podatkov uporabnika. Zato se morajo lastniki spletnih strani strinjati z tem, saj so podatki njihova last.

3.2.4 Razčlenjevanje vsebine HTML

Spletna stran je v osnovi dokument v jeziku HTML (angl. *HyperText Markup Language*), ki je organiziran v drevesno strukturo DOM (angl. *Document Object Model*) [58]. Vsak element dokumenta (naslov, odstavek in podatkovne celice), je v tej strukturi predstavljen kot vozlišče, ki ima lahko starševska in podrejena vozlišča. Orodja za razčlenjevanje (kot sta knjižnici BeautifulSoup [71] in lxml [7] v jeziku Python), to strukturo pretvorijo v obliko, ki so primerna za programsko obdelavo.

Za izluščevanje podatkovnih elementov iz razčlenjene strukture se v praksi najpogosteje uporabljata dve vrsti izbirnikov (angl. *selectors*): izbirniki CSS in izbirniki XPath [14]. Izbirniki CSS so bili prvotno zasnovani za oblikovanje spletnih strani, a jih pri zajemu podatkov preusmerimo v poizvedovanje po strukturi DOM [58]. Izbirniki XPath (angl. *XML Path Language*) pa predstavljajo namenski poizvedovalni jezik za navigacijo po drevesnih strukturah XML in HTML, ki poleg preprostega iskanja po oznakah in razredih vsebuje tudi premikanje (navzgor po drevesu, iskanje po vsebini besedilnih vozlišč ter vgrajene funkcije, (kot sta `contains()` in `position()` [14])).

V kontekstu zajemanja podatkov iz oglasnih portalov za vozila to pomeni, da lahko izbirniki iz razčlenjenega dokumenta izluščimo vsa ključna podatkovna polja oglasa.

Poglavje 4

Razvoj rešitve


Cilj diplomske naloge je bila izdelava prototipa spletne aplikacije, v katerem bodo uporabniki lahko objavljali oglase za prodajo svojih vozil. Pred začetkom razvoja smo morali najprej jasno opredeliti zahteve. Sledila ji je zasnova načrta naše rešitve, nato smo morali izbrati ustrezne tehnologije, kar smo storili na podlagi lastnih izkušenj in predznanja ter pregleda različnih forumov in strokovnih člankov. Ko smo zaključili razvoj prototipa spletne aplikacije, smo se lotili še ločenega razvoja sistema za vrednotenje vozil, ki je napisan v programskem jeziku Python. Python smo izbrali, ker je zelo primeren za obdelavo podatkov in razpolaga z bogatim ekosistemom knjižnic, namenjenih analizi podatkov.

4.1 Zahteve

Pred začetkom razvoja smo opredelili zahteve, ki jih delimo na funkcionalne in nefunkcionalne. Pri opredelitvi funkcionalnih zahtev ločimo dve vrsti uporabnikov: **anonimnega** in **registriranega**. Anonimni uporabnik lahko dostopa le do pregleda oglasov, medtem ko je registriranemu uporabniku omogočen dostop do celotne funkcionalnosti sistema. Funkcionalne zahteve so naslednje:

- Uporabnik se lahko registrira.
- Registriran uporabnik se lahko prijavi in odjavi.
- Oglaševanje vozil je omogočeno le registriranim uporabnikom.
- Registriran uporabnik lahko za vozilo z vnešenimi atributi (Znamka, model, letnik, prevoženi kilometri) oceni njegovo vrednost.
- Registriran uporabnik lahko vsečka oglase drugih uporabnikov.
- Registriran uporabnik lahko ažurira svoje objavljene in vsečkane oglase.
- Anonimni uporabnik lahko pregleduje objavljene oglase, ne more pa jih objavljati, vsečkati ali ovrednotiti vozil.

Na sliki 4.1 prikazujemo diagram primerov uporabe, ki povzema interakcije registriranega in anonimnega uporabnika s sistemom.



Slika 4.1: Diagram primerov uporabe za registriranega in anonimnega uporabnika.

Nefunkcionalne zahteve opredeljujejo kakovostne lastnosti sistema in so naslednje:


- Spletna aplikacija je hitra in odzivna. Uporabniški vmesnik se na dejanja uporabnika odzove praktično takoj (v manj kot 100 ms), zahtevki HTTP proti zalednemu sistemu (z izjemo vrednotenja vozila) pa se v večini primerov obdelajo v manj kot 300 ms.
- Sistem za vrednotenje vozil vrne oceno v kratkem času (manj kot 2 sekundi).
- Uporabniški vmesnik je intuitiven in enostaven za uporabo. Uporabnik lahko glavne naloge (ocena vrednosti vozila, objava oglasa, prijava)

opravi brez predhodnih navodil, saj so poti do njih vidne z glavne strani, obrazci pa sproti opozarjajo na napačno vnesene podatke.

- Spletna aplikacija je vizualno privlačna. Uporablja enoten slog (barve, tipografijo in razmike), ki je skladen na vseh pogledih, postavitev pa se prilagaja različnim velikostim zaslonov, od namiznih do mobilnih.
- Sistem ustrezno varuje vse uporabniške podatke, (gesla pred shranjevanjem zgosti in uporablja časovno omejene žetone JWT).
- Sistem ostane odziven tudi pri izvajanju zahtevnejših opravil, (uporablja sinhrono obdelavo).
- Arhitektura omogoča hitro in vzdržljivo dodajanje novih funkcionalnosti.

4.2 Arhitektura rešitve

Prototip spletne aplikacije je sestavljen iz uporabniškega vmesnika (odjemalec), strežniškega dela aplikacije (zaledni sistem) in ločenega sistema za vrednotenje vozil. Uporabniški vmesnik je razvit z uporabo knjižnice React [51] in programskega jezika TypeScript [53] v okolju Node.js različice 24 [59]. Zaledni sistem je razvit z uporabo ogrodja Express [12] v programskem jeziku JavaScript [22] v okolju Node.js različice 24. Sistem za vrednotenje vozil je implementiran kot ločena storitev v programskem jeziku Python različice 3.11 [65]. Na sliki 4.2 je prikaz arhitekture.



Slika 4.2: Arhitektura prototipa spletne aplikacije

Za izvajanje posameznih komponent je uporabljena platforma Docker [16] z vsebniki za, Zaledni sistem, Postgres(16), redis(7), mailhog in sistem za vrednotenje vozil.

Razvoj aplikacije je potekal v razvojnem okolju Visual Studio Code. Za avtomatizacijo preverjanja kode, izvajanja testov ter gradnje vsebnikov Docker je bil uporabljen sistem GitHub Actions [27], medtem ko so se periodična opravila izvajala s pomočjo časovno načrtovanih opravil (cron). Za gostovanje aplikacije je bil uporabljen virtualni strežnik ponudnika Hetzner [32]. Namestitev in upravljanje aplikacije na strežniku je bilo izvedeno s pomočjo platforme Dokploy [18].

4.3 Uporabne tehnologije

Poleg temeljnih tehnologij, ki so relativno znane in jih zato ne predstavljamo posebej, smo med razvojem uporabili še nekaj manjših ampak uporabnih knjižnic in orodij, za ožje probleme. V nadaljevanju jih na kratko predstavimo.

4.3.1 Upravljanje obrazcev s knjižnico React Hook Form

Uporabniški vmesnik vsebuje več obsežnejših obrazcev za izpolnjevanje. Ročno upravljanje takšnih obrazcev v knjižnici React [51] zahteva, da za vsako polje posebej vzdržujemo stanje, obravnavamo dogodke ob spremembi vrednosti in sami zapišemo logiko preverjanja vnosov, kar hitro privede do obsežne in težko vzdržljive kode.

Zato smo uporabili knjižnico React Hook Form [68]. Knjižnica stanje obrazca upravlja prek nenadzorovanih komponent (angl. *uncontrolled components*) in referenc, kar pomeni, da se ob vsakem pritisku tipke ne izriše celoten obrazec, temveč le tisti deli, ki jih sprememba dejansko zadeva. Posamezno polje prijavimo v obrazec, pri čemer hkrati navedemo še pravila preverjanja vnosa (angl. *validation*), na primer obveznost polja, najmanjšo dolžino ali regularni izraz. Napake so nato na voljo v objektu `errors`, iz katerega jih neposredno izpišemo ob pripadajočem polju. Preverjanje vnosov na strani odjemalca uporabnika opozori na napake, še preden se zahtevek sploh pošlje na strežnik, kar zmanjša število nepotrebnih zahtevkov.

4.3.2 Predpomnjenje strežniškega stanja s knjižnico TanStack Query

Del podatkov, ki jih prikazuje uporabniški vmesnik, izvira iz zalednega sistema in se razmeroma redko spreminja. Značilen primer so sezname znamk in modelov vozil, ki jih potrebujemo v skoraj vsakem obrazcu in filtru. Če bi te podatke ob vsakem prikazu komponente znova pridobivali s strežnika, bi obremenjevali zaledni sistem in podaljševali odzivni čas vmesnika.

Zato smo uporabili knjižnico TanStack Query [75]. Ta odgovore strežnika shrani v predpomnilnik, kjer je vsak odgovor označen s ključem poizvedbe (angl. *query key*). Ko komponenta zahteva podatke z že znanim ključem, jih knjižnica vrne takoj iz predpomnilnika, zahtevkov na strežnik pa izvede po potrebi v ozadju, prikaz pa osveži šele, ko prispe nov odgovor. Čas, po katerem se shranjeni podatki obravnavajo kot zastareli, določimo za vsak ključ

posebej.

4.3.3 Testiranje zalednega sistema

Zaledni sistem smo pokrili z avtomatiziranimi testi, ki jih izvajamo z ogrodjem Jest [50]. Jest je testno ogrodje za okolje Node.js [59], ki v enem samem paketu združuje izvajalnik testov, knjižnico trditev (angl. *assertions*) in podporo za simulacijo odvisnosti (angl. *mocking*).

Ker večina logike zalednega sistema ni izpostavljena kot posamezna funkcija, temveč kot pot vmesnika API, smo ogrodju Jest dodali še knjižnico Super-test [46]. Ta omogoča pošiljanje zahtevkov HTTP neposredno na aplikacijo Express, ne da bi strežnik dejansko poslušal na omrežnih vratih. V testu tako opišemo celotno pot zahtevka: ga pošljemo na določeno pot, priložimo žeton JWT ter nato preverimo statusno kodo in vsebino odgovora. Testi se izvajajo samodejno na cevovodu neprekinjene integracije ob vsakem zahtevku za združitve, kar podrobneje opisujemo v razdelku 4.8.2.


4.3.4 Približno ujemanje nizov s knjižnico RapidFuzz

Imena znamk in modelov vozil so pri različnih spletnih virih zapisana neenotno, zato jih z natančnim ujemanjem nizov ni mogoče zanesljivo povezati z imeni v podatkovni bazi. Za takšne primere smo uporabili knjižnico RapidFuzz [67], ki v jeziku Python omogoča približno ujemanje nizov (angl. *fuzzy string matching*). Knjižnica podobnost med nizoma izrazi kot oceno med 0 in 100, izračunano na podlagi urejevalne razdalje (angl. *edit distance*), pri čemer so vse zahtevnejše operacije implementirane v jeziku C++ [38] in so zato bistveno hitrejše od enakovrednih izvedb v jeziku Python. Konkreten postopek ujemanja in izbrane pragove opisujemo v razdelku 4.7.1.

4.4 Načrtovanje podatkovne baze

4.4.1 Načrtovanje podatkovne baze aplikacije

Pri načrtovanju podatkovne baze smo morali natančno premisliti, kako shranjujemo oglase vozil, saj je to ključnega pomena za učinkovito delovanje odločitvenega modela. Previsoka stopnja normalizacije bi lahko upočasnila poizvedbe, prenizka pa bi vodila do podvajanja podatkov in z zagotavljanjem skladnosti v bazi [19]. Zasnovani podatkovni načrt je predstavljen na sliki 4.3.



Slika 4.3: ER-diagram glavnih entitet aplikacije.

Entiteti **Brand** in **CarModel** sta izločeni v ločeni tabeli, ker med njima obstaja hierarhično razmerje ena-proti-mnogo: ena znamka (**Brand**) ima lahko poljubno število modelov (**CarModel**), vsak model pa pripada natanko eni znamki. Shranjevanje znamk in modelov kot vrednosti tipa **enum** ali prostega niza bi bilo neprimerno iz dveh razlogov. Število možnih vrednosti je


namreč preveliko za statično definicijo z `enum`, prosti niz pa bi omogočal podvojene ali nekonsistentne vnose (na primer „Audi A3“ in „audi a3 Sportback“ bi bila obravnavana kot različni entiteti, čeprav gre za isti model). Z relacijsko vezavo prek tujih ključev je zagotovljen referenčni nadzor nad vnesenimi vrednostmi ter enotnost podatkov.

Entiteta `CarSpecifications` je namerno ločena od entitete `CarListing`, ker vsebuje tehnične podrobnosti vozila, ki niso relevantne pri vsakem poizvedovanju. Pri prikazu seznama oglasov (npr. v podatkovni tabeli) zadostujejo le osnovni podatki iz entitete `CarListing` (cena, prevoženi kilometri in letnik), podrobne specifikacije pa se naložijo le ob ogledu posameznega oglasa. Ta ločitev zmanjša količino podatkov, ki se prenesejo iz podatkovne baze pri pogostih poizvedbah, in s tem izboljša odzivnost aplikacije.

Entiteta `CarListingLike` predstavlja asociativno tabelo, ki realizira razmerje mnogo-proti-mnogo med uporabniki in oglasi: en uporabnik lahko všečka poljubno število oglasov, en oglas pa je lahko všeč pri poljubnem številu uporabnikov. Tabela vsebuje tuji ključ na entiteto `User` in tuji ključ na entiteto `CarListing`, kar zagotavlja referenčno integriteto in preprečuje podvojene vnose. Entiteta `User` hrani ključne podatke o registriranih uporabnikih sistema.

4.4.2 Načrtovanje podatkovne baze za ovrednotenje vozil

V okviru iste podatkovne baze smo dodali ločeno shemo `market`, ki vsebuje dve tabeli. Namenjeni zbiranju in obdelavi tržnih podatkov za sistem vrednotenja vozil 4.4..



Slika 4.4: ER-diagram sistema za vrednotenje vozil.

Tabela **RawMarketListing** služi kot neobdelan arhiv vseh oglasov, ki so pridobljeni iz zunanjih virov – javno dostopnih zbirk podatkov, spletnih vmesnikov API in z zajemanjem spletnih strani. Tabela vsebuje naslednja polja:

- **source** določa izvor podatkov (npr. ime portala ali vmesnika API),
- **externalId** je identifikator oglasa na izvornem sistemu, ki je določen statično v kodi in preprečuje podvojene vnose,
- **url** hrani neposredno povezavo do oglasa,
- **scraped_at** je časovni žig trenutka zajema podatkov,
- **raw_payload** vsebuje izvorni odgovor v obliki JSON brez kakršnekoli obdelave.


Izvorni odgovor je namerno shranjen v celoti, kar omogoča kasnejšo ponovno obdelavo brez ponovnega zajema podatkov, če se normalizacijska logika spremeni.

Tabela `NormalizedCarListing` vsebuje obdelano in normalizirano obliko oglasov, ki so vezani na tabelo `RawMarketListing` prek tujega ključa `raw_listing_id`. Razmerje med tabelama je ena-proti-mnogo: vsak surovi oglas ima lahko več normaliziranih zapisov, katere razlikuje primarni ključ. Isto vozilo, pa razlikuje tuji ključ od `RawMarketListing`. Polja so poenotena in tipizirana; cena, prevoženi kilometri in letnik so shranjeni kot `integer`, znamka, model, vrsta goriva, tip menjalnika, oblika karoserije in država pa kot `string`. Takšna poenotena struktura omogoča neposredno primerjavo oglasov iz različnih virov pri izračunu tržne vrednosti vozila.

Ločitev na dve tabeli predstavlja cevovoda surovih in normaliziranih podatkov (angl. *raw/normalized pipeline*) [43]: surovi podatki ostanejo nedotaknjeni kot revizijska sled in osnova za morebitno ponovno obdelavo, normalizirana oblika pa je tista, ki se uporablja v analitičnih poizvedbah.

4.5 Arhitektura zalednega sistema

Zaledni sistem smo oblikovali z modularno arhitekturo, ki omogoča jasno ločitev odgovornosti (angl. *separation of concerns*), kar olajša branje, vzdrževanje in nadaljnjo razširitev kode [15]. V naslednji sliki je bolj podrobno prikazana arhitektura zalednega sistema 4.5.



Slika 4.5: Arhitektura zalednega sistema

4.5.1 Modul za poizvedbe v podatkovni bazi

Za implementacijo podatkovnih modelov in poizvedb na podatkovno bazo smo uporabili knjižnico Sequelize [13]. Sequelize [13] je vmesnik za spreminjanje objektno-relacijskih preslikav (angl. *Object-Relational Mapping*), ki omogoča preslikavo objektov iz programske kode v relacijske strukture podatkovne baze [13]. Tak pristop izboljšuje razvoj, saj omogoča programerjem, da namesto neposrednih poizvedb SQL delajo z objekti, kar zmanjša napake in poveča berljivost kode. Prednosti pristopa vključujejo tipsko varnost, avtomatično generiranje poizvedb za različne podatkovne baze ter intuitivnejše upravljanje relacij med entitetami.

Podatkovni modeli so v Sequelize definirani kot razredi, ki predstavljajo tabele v bazi podatkov [13]. Vsak model ima attribute, ki ustrezajo stolpcem v tabeli, ter metode za izvajanje temeljnih operacij s podatki (CRUD – Create, Read, Update, Delete). Ključna pri oblikovanju modelov je tudi postavitve indeksov na poljih, ki se pogosto pojavljajo pri poizvedbah (npr. ID vozila, izvor oglasa ali časovni žigi). Dobro zasnovani indeksi so bistvenega pomena za zagotavljanje hitrih odgovorov poizvedb pri velikih količinah podatkov [25]. Primer postavitve povezave z bazo podatkov je v kodi 1.

Izsek kode 1: Koda za vzpostavitev povezave z bazo podatkov.

```
1 import { Sequelize } from 'sequelize';
2
3 const sequelize = new Sequelize(process.env.DB_NAME, process.env.DB_USER,
4   ↪ process.env.DB_PASSWORD, {
5     host: process.env.DB_HOST,
6     port: process.env.DB_PORT,
7     dialect: 'postgres',
8     logging: false,
9   });
10 export default sequelize;
```

4.5.2 Avtentikacija in avtorizacija uporabnikov


Za avtentikacijo uporabnikov smo implementirali sistem, ki temelji na žetonih JWT (JSON Web Token), kar omogoča varen in enostaven prenos podatkov o uporabnikovi pristnosti [40]. Žeton JWT je strukturiran dokument, ki je sestavljen iz treh delov: glave (angl. *header*), ki vsebuje metapodatke o vrsti kodiranja; *podatkov* (angl. *payload*), ki nosijo informacije o uporabniku; in *digitalnega podpisa*, ki zagotavlja celovitost in pristnost žetona [40]. Postopek avtentikacije je razdeljen na dve fazi. V fazi registracije uporabnik vnese svoje geslo, ki ga pred shranitvijo v podatkovno bazo zgostimo z algoritmom bcrypt [64]. Bcrypt je specializirana kriptografska funkcija, namenjena zgoščevanju gesel. V fazi prijave uporabnik pošlje svoje geslo in e-poštni naslov. Zaledni sistem pridobi shranjeno zgoščeno geslo iz baze in ga primerja z novim zgoščenim geslom. Če se gesli ujemata, zaledni sistem generira žeton JWT z informacijami o uporabniku in ga vrne uporabniškemu vmesniku, kjer ga uporabnik shrani v brskalniku največkrat v shrambo seje (angl. *localStorage*).

Za zaščito poti vmesnika API smo implementirali sredinski sistem za preverjanje žetonov. Vmesnik je funkcija, ki se izvede pred vsakim zahtevkom in preveri, ali je uporabnik v zahtevku poslal veljaven žeton JWT. Dodatna varnostna plast je nastavljena s časovnimi omejitvami žetona, ki zagotavlja, da je žeton veljaven samo za določen čas. Po preteku roka veljavnosti se mora uporabnik ponovno avtentificirati in pridobiti nov žeton, kar zmanjšuje tveganje ob morebitnem razkritju starejših žetonov [73]. Koda za prijavo uporabnika je prikazana v kodi 2, prijava in registracija je pa sta na sliki 4.6.

Izsek kode 2: Koda za prijavo uporabnika.

```
1 export const loginUserService = async ({ email, password }) => {  
2   try {  
3     if (!email || !password) throw new MissingUserDataError();  
4  
5     const user = await User.findOne({ where: { email } });
```

```
6
7   if (!user) throw new AppError('Invalid email or password', 401);
8
9   const isPasswordValid = await bcrypt.compare(password, user.password);
10
11  if (!isPasswordValid) throw new AppError('Invalid email or password',
12    ↪ 401);
13
14  const token = jwt.sign({ id: user.id, email: user.email },
15    ↪ process.env.JWT_SECRET, {
16    expiresIn: '7d',
17  });
18
19  await emailQueue.add('login', { type: 'login', to: user.email,
20    ↪ userName: user.firstName });
21
22  return { user, token };
23 } catch (error) {
24   throw error;
25 }
```



Slika 4.6: Prijava in registracija na prototipu.

4.5.3 Asinhrona obdelava podatkov

Za naloge, ki zahtevajo obsežnejšo obdelavo podatkov ali imajo daljši čas izvajanja, smo implementirali asinhrono obdelavo z uporabo sistema čakalnih vrst nalog. Ta pristop omogoča, da strežnik takoj odgovori na zahtevek,

medtem ko se zahtevnejše operacije izvajajo v ozadju kot ločeni procesi. Na ta način se izboljša splošna odzivnost aplikacije [43]. Značilne naloge, ki zahtevajo asinhrono obdelavo, so večinoma zajem podatkov iz zunanjih virov, normalizacijo in transformacijo zajetih podatkov ter pošiljanje e-poštnih obvestil uporabnikom [43]

Za upravljanje čakalnih vrst nalog v okolju Node.js smo izbrali knjižnico BullMQ [11], ki zagotavlja zanesljivo upravljanje tovrstnih nalog z vgrajeno podporo za ponovne poskuse (angl. *retry*), časovne omejitve (angl. *timeout*) in obravnavo napak [11]. Sistem temelji na kombinaciji podatkovnega skladišča Redis [69] in delovnih procesov. Redis v tej arhitekturi služi kot posrednik sporočil (angl. *message broker*), ki hrani stanje nalog in omogoča koordinacijo med posameznimi delovnimi procesi [69].

Konfiguracija sistema zahteva tri ključne korake. Najprej se vzpostavi povezava s strežnikom Redis [69]. Nato se registrirajo delovni procesi, ki poslušajo dodeljene vrste nalog, jih obdelujejo in ustrezno posodablajo stanje v skladišču Redis. S takšno zasnovo je zagotovljeno, da se dolgotrajne operacije ne izvajajo na glavni niti aplikacije, kar omogoča sočasno obdelavo in izboljšano razširljivost sistema.

4.6 Arhitektura uporabniškega vmesnika

Uporabniški vmesnik smo zasnovali iz več komponent, ki skupaj sestavljajo celoto. Tudi tu smo upoštevali načela modularnosti, ki omogočajo ponovno uporabo komponent ter lažje vzdrževanje kode [62]. Vsako komponento smo oblikovali tako, da opravlja natančno določeno nalogo in prikazuje omejen del vmesnika. Komponente smo namenoma ohranili majhne, saj majhen obseg naravno usmerja razvijalca k temu, da posamezna komponenta ostane osredotočena na eno samo funkcionalnost. Komponente si med seboj izmenjujejo podatke po hierarhiji nadrejenih in podrejenih komponent. Nadrejena komponenta posreduje podatke podrejenim komponentam prek lastnosti (angl. *props*), podrejena komponenta pa nadrejeni sporoča spremembe prek povra-

The diagram illustrates the architecture of a car stock market application, organized into several key components and layers:

- 3. LAYOUTI** (Layouts):
 - MainLayout**: MainHeader + <main> + Toast
 - AuthLayout**: AuthHeader + <main> + Toast
- 4. HEADERJI** (Headers):
 - BaseHeader**: logo, (če prijavljen) avatar / profil, logout, bere useAuthService
 - MainHeader**: logo, navigacija, login / register (če ni seje), bere useAuthService
 - AuthHeader**: samo logo
- 5. STRANI (src/pages) in ključne komponente** (Pages and Key Components):
 - HomePage**: SetYourCarSection, PinPoints, FeaturedCars, getFeaturedCarListing() → CarListingCard()
 - BrowseCarsPage**: QuickFilter, fetchCarBrand() / fetchBrandModels() → emitFilters(), CarListingGrid, getCarListingsByFilters() → CarListingCard(), Pagination
 - CarDetailsPage**: getCarListingId() / getCarSellerId(), CarDetailsPhotos (> 14x6), CarDetailsSpecifications, CarDetailsPrice, CarDetailsSellerCard, SafetyTips
 - EvaluationPage (priceYourCar)**: evaluateCar (useMutation), VehicleInformation (RHF + Zod) (brands/models), VehicleEstimation, createCarListing (FormData)
 - CarListing Wizard**:
 1. FirstPageCarListing (convozi) podataci
 2. SecondPageCarListing (specifikacije)
 3. ThirdPageCarListing (fotografije)
 4. FourthPageCarListing (pregled & odjava) → createCarListing (FormData)
 - Auth Pages**: LoginPage (RHF + Zod), RegistrationPage (RHF + Zod), RegistrationVerificationCode, registerUser()
- 6. GLOBALNO STANJE** (Global State):
 - useAuthService**:
 - user
 - hasFetchedUser
 - setUser(user)
 - fetchUser() → GET /api/users/me
 - logout() → POST /api/users/logout
 - carListingStore** (3 store-i):
 - useCarListingFirstPageStore
 - useCarListingSecondPageStore
 - useCarListingThirdPageStore
 - clearAllCarListingStores()
- 7. SERVER STATE (TanStack React Query)**:
 - QueryClient**:
 - background updates
 - invalidateQueries()
 - mutations
- 8. API LAYER**:
 - axios instance**:
 - baseURL = VITE_API_BASE_URL
 - withCredentials: true
 - UserApi**: registerUser, switchAuthTokenCode, loginUser, getCarData, getNewCarListings, getUsedCarListings
 - CarApi**: fetchCarDetails, fetchBrandModels, evaluateCar
 - CarListingApi**: createCarListing, getCarListings, getCarListing, getCarSeller, listCarListing, deleteCarListing, getFeaturedCarListings
- 9. BACKEND REST API**: Express - Car Stock Market BE

Slika 4.7: Arhitektura odjemalčevega sistema

4.6.1 Odjemalska shramba

Določene podatke si mora odjemalec zapomniti, kar pomeni, da jih mora shraniti na svoji strani. Prednost odjemalske shrambe je, da odjemalcu ni treba nenehno pošiljati novih zahtevkov na strežnik, kar občutno zmanjša njegovo obremenitev. Značilen primer uporabe je shranjevanje žetona JWT, ki ga uporabnik prejme ob prijavi in ga nato pri vsakem zahtevku pošilja v glavi [40]. Na ta način imamo podatke o prijavljenem uporabniku ves čas na voljo, dokler se ta ne odjavi ali dokler žeton JWT ne poteče.

Odjemalska shramba je uporabna tudi pri večkoračnih postopkih, saj si lahko zapomnimo, do katerega koraka je uporabnik prišel. Če uporabnik namerno

ali nenamerno zapre stran, ostane njegovo napredovanje ohranjeno in lahko z delom nadaljuje. Pri shranjevanju podatkov na odjemalcu moramo biti pozorni, da hranimo le neobčutljive podatke ter da stanje pravilno posodobljamo ob vsaki spremembi. Spletni brskalniki za trajno hrambo podatkov na strani odjemalca ponujajo več mehanizmov, med drugim `localStorage` in `sessionStorage` [82]. V nasprotnem primeru se lahko stanje na odjemalčevi strani razlikuje od stanja na strežniku, kar lahko vodi do napak.

Za odjemalsko shrambo smo uporabili knjižnico Zustand [63], ki je preprosta, kompaktna in dobro vzdrževana. Zustand [63] temelji na minimalističnem pristopu k upravljanju stanja in za osnovno delovanje ne zahteva ovojnih komponent (angl. *provider*), kar ga loči od nekaterih drugih uveljavljenih rešitev, kot je recimo Redux [70]. Stanje je organizirano v obliki t.i. shramb (angl. *store*), do katerih dostopamo prek preprostih kavljev (angl. *hooks*), pri čemer se ponovno izrišejo le tiste komponente, ki dejansko uporabljajo spremenjeni del stanja. Zaradi majhne velikosti in neodvisnosti od ogrodja React je knjižnica primerna tudi za projekte, pri katerih želimo ohraniti nizko zahtevnost in dobro zmogljivost.

4.6.2 Zahtevki API

Za pošiljanje zahtevkov smo uporabili knjižnico Axios, ki je ena izmed najbolj razširjenih knjižnic za pošiljanje zahtevkov HTTP v okolju JavaScript [22, 5]. Nad njo smo izdelali ovojnico `api`, ki iz okoljskih spremenljivk (angl. *environment variables*) prebere naslov strežnika in ga uporabi kot osnovni naslov URL za vse zahteve. Tak pristop nam omogoča, da osnovni naslov in skupne nastavitve določimo na enem mestu, s čimer se izognemo ponavljanju in poenostavimo morebitne kasnejše spremembe. V kodi 3 je prikazana ovojnica, ki jo nato uvozimo v vsako datoteko, kjer definiramo funkcije za pošiljanje zahtevkov.

Izsek kode 3: Ovojnica Axios za ustvarjanje odjemalca API.

```
1 import axios from "axios";
2
3 const api = axios.create({
4   baseURL: import.meta.env.VITE_API_BASE_URL,
5   withCredentials: true,
6 });
7
8 export default api;
```

Ovojnico smo nato uporabili pri vsaki definiciji funkcije za pošiljanje zahtevka. Funkcija vrne polje `res.data`, ki vsebuje dejanski odgovor strežnika. Axios namreč vrne objekt s številnimi dodatnimi podatki, ki niso vedno potrebni, zato zaradi preglednosti kode vrnemo le vsebino odgovora [5]. Po potrebi lahko dostopamo tudi do statusne kode strežnika, glave odgovora in konfiguracije zahtevka. Primer definicije funkcije za pridobivanje znamk vozil je prikazan v kodi 4.

Izsek kode 4: Primer definicije funkcije za pridobivanje znamk vozil.

```
1 export const fetchCarBrands = async () => {
2   const res = await api.get<{ brandNames: string[] }>("/api/cars/brands");
3   return res.data;
4 };
```

4.6.3 Razvojno orodje Vite

Vsako izvorno kodo je treba pred prikazom v spletnem brskalniku ustrezno pripraviti oziroma zgraditi. To nalogo v našem projektu opravlja orodje Vite [79], ki omogoča hitro postavitve razvojnega okolja in izgradnjo končne različice aplikacije. Za razliko od starejših orodij za združevanje kode (angl. *bundler*) (kot je Webpack [81], ki mora ob vsaki spremembi znova zgraditi večji del kode), Vite tega ne počne in je zato bistveno hitrejši.

Delovanje orodja Vite [79] temelji na dveh ključnih načelih. Prvo je izraba nativne podpore modulom ECMAScript [55] (angl. *ES modules*) v sodobnih

brskalnikih. Ker sodobni brskalniki neposredno razumejo uvožene module, Vite med razvojem kode ne združuje, temveč posamezne module dostavi brskalniku po potrebi [79, 55]. Drugo načelo je uporaba orodja esbuild [80] za predhodno izgradnjo odvisnosti JavaScript [22]. Orodje je napisano v jeziku Go [28] in je od 10 do 100-krat hitrejše od orodij za združevanje, ki so napisana v jeziku JavaScript.

Pomembna prednost orodja Vite je zmožnost sprotnega osveževanja modulov (angl. *Hot Module Replacement*), pri katerem se osveži le tisti del kode, ki se je spremenil, brez izgube trenutnega stanja in podatkov aplikacije. Ta zmožnost je pri razvoju izjemno pomembna, saj občutno pospeši povratno zanko med spremembo in prikazom ter tako poveča produktivnost.

4.7 Sistem za vrednotenje vozil

Sistem za vrednotenje vozil smo zasnovali kot samostojno storitev, ki smo jo razvili v programskem jeziku Python. Pri razvoju smo z osnovnim jezikom postopoma dodajali pakete glede na potrebe. Za komunikacijo z zalednim sistemom smo potrebovali spletni strežnik, saj je zaledni sistem edini, ki ima dostop do sistema za vrednotenje vozil. Za spletni strežnik in vmesnik API smo uporabili ogrodje FastAPI, ki omogoča enostavno izdelavo vmesnikov API v jeziku Python [66]. Na izseku kode 5 je prikazan primer definicije vmesnika API, ki vrne seznam znamk vozil iz podatkovne baze 5.

Izsek kode 5: Primer definicije vmesnika API z ogrodjem FastAPI

```
1 @app.get("/car-brands")
2 def get_car_brands():
3     return getCarBrands()
```

Podatkovno bazo smo ločili v samostojno shemo z lastnimi modeli, s čimer smo se izognili morebitni zmedi pri poimenovanju in strukturi. Za migracijo tabel in podatkov smo dodali paket Alembic, ki je zmogljivo orodje za

upravljanje in posodabljanje podatkovnih baz [6]. Alembic sledi shemi podatkovne baze in samodejno ustvarja migracijske skripte, ki jih je mogoče verzionirati skupaj z izvirno kodo, kar zagotavlja ponovljivo in nadzorovano spreminjanje strukture podatkovne baze. Pri tem projektu smo se prvič srečali s tehnologijo cron [76]. Ta omogoča samodejno izvajanje ukazov ob vnaprej določenih časovnih intervalih na strežniku ali v drugem okolju. Cron smo uporabili za zagon programov za samodejni zajem podatkov s spletnih strani za prodajo vozil. Ti programi se na strežniku izvajajo dnevno oziroma tedensko.

4.7.1 Algoritem za primerjavo vozil



Slika 4.8: Algoritem za primerjavo vozil

Opis algoritma v nadaljevanju sledi korakom s slike 4.8, od leve proti desni in od zgornje vrstice k spodnji. Začeli smo z zajemom podatkov o oglasov vozil, bodisi s samodejnim zajemom s spletnih strani za prodajo vozil ali pa z dostopom do javno dostopnih virov. Sam postopek zajema smo podrobneje opisali v poglavju 3.2, njegovo samodejno periodično izvajanje pa temelji na tehnologiji cron; tu se osredotočamo na nadaljnjo obdelavo zajetih podatkov.

Zajete podatke najprej shranimo v surovi, nestrukturirani obliki, tako kot pridejo z vira. S tem zajem ločimo od obdelave: če postopek normalizacije pozneje popravimo ali v njem odkrijemo napako, ga lahko ponovimo nad shranjenimi surovimi podatki. Sledi normalizacija, s katero surove podatke pretvorimo v enotno obliko. Za vsak spletni vir smo morali napisati ločen postopek normalizacije.

Za vsako vozilo normaliziramo in shranimo ceno, prevožene kilometre, znamko, model, moč motorja, vrsto menjalnika in vrsto goriva. Pri normalizaciji smo vse te podatke sproti izpisovali in poskrbeli za zanesljiv sistem obvladovanja napak. Zlasti v začetni fazi razvoja namreč pogosto prihaja do napak, za njihovo učinkovito odpravljanje pa je potreben podroben izpis poteka izvajanja [84].

Poleg razlik v strukturi se posamezni viri med seboj razlikujejo tudi v zapisu posameznih vrednosti. Cene so lahko zapisane z ločilom tisočic, ki jih je treba pred pretvorbo v število odstraniti. Prevoženi kilometri so pri enem viru zapisani kot celo število, pri drugem pa kot niz z enoto (na primer „123.456 km“). Datum prve registracije je pri enem viru zapisan v obliki *mesec/leto*, pri drugem pa *leto/mesec*. Podobno je bilo treba poenotiti kategorije, za tip menjalnika in vrsto goriva, saj so viri te podatke podajali v različnih jezikih. Poseben korak v tej fazi je ujemanje znamke in modela vozila, ki je hkrati največji izziv normalizacije, saj sta ista znamka ali model na različnih virih pogosto zapisana drugače (okrajšave, dodatne besede, jezikovne razlike – na primer nemško „3er“ ali „Klasse“/„class“). Zato smo zgradili sistem ujemanja, ki surovo ime najprej poskuša natančno ujeti s kanoničnim imenom v podatkovni bazi, nato preveri tabelo že znanih psevdonimov (vodeno posebej za vsak vir), šele nazadnje pa uporabi približno (angl. *fuzzy*) ujemanje nizov [56] s knjižnico **RapidFuzz** (razdelek 4.3.4). Prag ujemanja smo nastavili na 90 % za znamke in 75 % za modele. Nižji prag za modele smo izbrali zato, ker so imena modelov krajša in bolj podvržena lažnim ujemanjem. Vsako uspešno približno ujemanje se samodejno shrani kot nov psevdonim za dani vir, s čimer se sistem sproti uči. Tako se vsak naslednji pojav istega zapisa razreši že

v fazi iskanja psevdonimov, s čimer se izognemo počasnejšemu približnemu ujemanju. Del kode, ki izvaja ujemanje znamke, je prikazan v kodi 6.

Izsek kode 6: Ujemanje znamke s dejanskim in približnim ujemanjem

```
1 def match_brand(raw: str, source: str):
2     normalized = normalize_text(raw)
3     brands = _get_all_brands()
4
5     for brand_id, canonical_name in brands:
6         if normalize_text(canonical_name) == normalized:
7             return brand_id, canonical_name
8
9     cached = _lookup_brand_alias(normalized, source)
10    if cached:
11        return cached
12
13    brand_names = [normalize_text(b[1]) for b in brands]
14    result = process.extractOne(normalized, brand_names,
15                               ↪ scorer=fuzz.WRatio)
16
17    if result is None or result[1] < 90:
18        print(f"[matching] No brand match for '{raw}', best score:
19              ↪ {result[1] if result else 0}")
20        return None
21
22    brand_id, canonical_name = brands[result[2]]
23    _store_brand_alias(normalized, brand_id, canonical_name, source)
24    return brand_id, canonical_name
```

S tem je prva faza s slike 4.8 zaključena: po normalizaciji so vsi podatki o oglasih vozil poenoteni v enotno strukturo (znamka, model, letnik, prevožena kilometrina, cena itd.), kar je predpogoj za primerjavo posameznih oglasov. Sledi druga faza, ocena tržne vrednosti. Njen prvi korak je vzeti vhodne parametre uporabnika. Implementirali smo API `/value`, ki za vhodne parametre sprejme znamko, model, letnik in prevoženo kilometrino vozila, za katero uporabnik želi oceno tržne vrednosti. V tej fazi smo se namenoma omejili zgolj na navedene štiri parametre, saj je bil primarni cilj dokazati, da

algoritem deluje na konceptualni ravni (angl. *proof of concept*), preden bi ga razširili na dodatne spremenljivke (npr. opremljenost, vrsto goriva, menjalnik, stanje vozila).

Dodajanje večjega števila parametrov brez zadostne količine normaliziranih podatkov bi namreč vzorec primerljivih vozil dodatno skržilo, zaradi česar bi jih hitro ostalo premalo za smiselno statistično oceno.

Po svoji zasnovi algoritem ustreza pristopu primerljivih prodaj (angl. *comparable sales approach*), ki je uveljavljena metoda vrednotenja nepremičnin in vozil [36]. Cene predmeta pri tem pristopu ne ocenjujemo na podlagi enega samega primerka, temveč na podlagi množice podobnih, dejansko prodanih (oz. oglaševanih) primerkov, ki jim glede na stopnjo podobnosti pripišemo različno utež. V statističnem smislu gre za obliko metode *k*-najbližjih sosedov (angl. *k-nearest neighbors*, *k*-NN) [1], pri kateri namesto ostre meje „sosed / ni soсед“ uporabimo zvezno utežno funkcijo, ki pada proti nič, ko se primerjano vozilo bolj razlikuje od ocenjevanega.

Rezultat algoritma pri tem ni zgolj ena sama cena, temveč cenovni razpon z dodatnimi pokazatelji kakovosti ocene; podrobneje ga opišemo pri zadnjem koraku v razdelku 4.7.4.

4.7.2 Filtriranje kandidatov iz podatkovne baze

Tukaj je opisan korak iskanja primerljivih vozil s slike 4.8. Izvede se s poizvedbo SQL, ki iz tabele `market.normalized_market_listing` izlušči kandidate za primerjavo. Znamko in model filtriramo strogo (po enakosti), saj najmočnejše določata segment in bazno ceno vozila.

Numerični spremenljivki pa filtriramo z dovoljenim odstopanjem: pri kilometrini znaša $\pm 40\,000$ km (konstanta `KILOMETERS_DIFFERENCE`), pri letniku pa ± 3 leta (konstanta `YEAR_DIFFERENCE`). Navedeni meji nista bili izbrani naključno, temveč predstavljata kompromis med natančnostjo in velikostjo vzorca. Če meji postavimo ožje, so vrnjena vozila bolj primerljiva glede na ocenjevano vozilo, a je hkrati manjši vzorec, iz katerega algoritem izračuna oceno, kar poveča statistično negotovost. Gre za znano razmerje med

pristranskostjo in varianco (angl. *bias-variance trade-off*) [31]. Ker je podatkovna baza normaliziranih podatkov vsaj v tej fazi razvoja še razmeroma majhna, smo se zavestno odločili za širši interval, da algoritem sploh pridobi dovolj velik vzorec za smiselno oceno. Ob prihodnji rasti podatkovne baze bi bilo smiselno ta interval zožiti oziroma ga določiti dinamično (v odvisnosti od števila zadetkov ožjega intervala), s čimer bi izboljšali natančnost ocene, brez da bi ta izhajala iz premajhnega vzorca.

4.7.3 Točkovanje podobnosti posameznega vozila

Tukaj opišemo korak uteževanja podobnosti s slike 4.8. Za vsako vozilo iz filtrirane množice izračunamo oceno podobnosti (angl. *score*) glede na ocenjevano vozilo. Uporabili smo dve delni oceni, (prvo za kilometrino in drugo za letnik), ki ju nato združimo v skupno oceno. Koda 7 predstavlja ta del izračuna.

Izsek kode 7: Izračun ocene podobnosti posameznega vozila

```
1 def get_scores_of_each_car(data_compare: dict, cars: list) -> list[tuple]:
2     results = []
3     for car in cars:
4         absolute_dif = abs(int(car["kilometers"]) -
5             ↪ int(data_compare["kilometers"]))
6         kilometers_score = max(0, 100 * (1 - absolute_dif /
7             ↪ KILOMETERS_DIFFERENCE))
8
9         absolute_dif = abs(int(car["registration_year"]) -
10             ↪ int(data_compare["year"]))
11         registration_year_score = max(0, 100 * (1 - absolute_dif /
12             ↪ YEAR_DIFFERENCE))
13
14         total_score = kilometers_score * 0.6 + registration_year_score *
15             ↪ 0.4
16         results.append((float(car["price"]), total_score))
17     return results
```

Obe delni oceni sta zasnovani po istem načelu: vozilo, ki je identično ocenjevanemu, prejme največ 100 točk, vozilo na robu dovoljenega intervala (z odstopanjem natanko 40 000 km ali 3 leta) pa 0 točk. Med tema skrajnostma ocena linearno pada, funkcija $\max(0, \dots)$ zagotavlja, da ocena nikoli ne postane negativna. Ker vozila zunaj dovoljenega intervala zaradi filtriranja v poizvedbi SQL sploh ne pridejo do tega koraka, gre pri tem predvsem za dodatno varnostno mejo.

Za linearno padajočo funkcijo (namesto eksponentne) smo se odločili iz dveh razlogov. Najprej zaradi enostavnosti in jasnosti, saj je linearna funkcija bolj razumljiva in preverljiva, kar je za prikaz delovanja koncepta, pomembnejše od mogočega izboljšanja natančnosti. Drugi razlog enostavno umerjanje, saj z eno samo konstanto natančno določimo, kje ocena doseže ničlo.

Skupno oceno podobnosti izračunamo kot uteženo vsoto obeh delnih ocen, pri čemer kilometrini pripišemo višjo utež (60 %) kot letniku (40 %). Vozili istega letnika se tako bolj razlikujeta po dejanski obrabi, če je prvo prevozilo 50 000 km, drugo pa 200 000 km. Vozili s podobno kilometrino, a nekoliko različnim letnikom pa ostajata bolj primerljivi.

4.7.4 Izračun ocenjene cene z uteženim povprečjem

Tukaj sta opisana zadnja koraka druge faze s slike 4.8 in sicer izračun ocene in njegov rezultat. Ko vsa primerljiva vozila ovrednotimo z oceno podobnosti, končno ocenjeno ceno izračunamo kot uteženo povprečje njihovih cen, pri čemer je utež vsakega vozila prav njegova izračunana ocena podobnosti:

$$\text{estimated_price} = \frac{\sum_i \text{price}_i \cdot \text{score}_i}{\sum_i \text{score}_i} \quad (4.1)$$

Uporaba uteženega povprečja namesto navadnega aritmetičnega je ključna: če bi izračunali navadno povprečje cen vseh vozil znotraj intervala, bi vozilo z roba intervala (39 000 več km), prispevalo enako kot vozilo, ki ima le 500 več km. To je neustrezno, saj je slednje veliko boljši pokazatelj dejanske cene. Z uteževanjem po vrednosti `total_score` pa bolj podobna vozila sorazmerno

bolj vplivajo na končno oceno, vozila na robu intervala pa prispevajo le malo. Standardna oblika uteženega povprečja (angl. *weighted mean*) [8], poskrbi da vsota uteži v imenovalcu pravilno določi rezultate, ne glede na število vozil ali velikost njihovih ocen.

Poleg ocenjene cene algoritem vrne tudi indeks zaupanja (angl. *confidence*), ki je izračunan po enačbi:

$$\text{confidence} = \min\left(1.0, \frac{n}{20}\right), \quad (4.2)$$

pri čemer je n število vozil, najdenih znotraj filtriranih meja. To pove uporabniku stopnjo zaupanja v ceno, ki smo mu jo posredovali. Če je število primerjalnih vozil veliko, je indeks zaupanja bližje 1, sicer pa je indeks zaupanja bližje 0. Tudi tu je vrednost 20 določena heuristično in bi jo lahko spremenili

Rezultat algoritma tako ni zgolj ena sama cena. Vmesnik `/value` vrne ocenjeno (pričakovano) prodajno ceno, poleg nje pa še spodnjo mejo ugodne cene (`goodPrice`), zgornjo mejo precenjene cene (`badPrice`) in iz njiju izpeljano razmerje `ratio`, ki pove, kako razpršene so cene primerljivih vozil na trgu. Pri tem sta pomembni dve podrobnosti. Prvič, pri izračunani ceni upoštevamo popust, saj se rabljena vozila praviloma prodajo ceneje, kot so oglaševana. Drugič, razmerje `ratio` med `badPrice` in `goodPrice` je poleg indeksa zaupanja drugi pokazatelj kakovosti ocene: meri širino cenovnega razpona primerljivih vozil in s tem, koliko prostora ima uporabnik pri pogajanju.

4.8 Infrastruktura in avtomatizacija

Poleg implementacije posameznih komponent je bil pomemben del razvoja tudi vzpostavitev infrastrukture, ki zagotavlja konsistentno delovanje sistema v različnih fazah njegovega življenjskega cikla; od lokalnega razvoja, prek avtomatiziranega preverjanja kode, do namestitve v produkcijsko okolje. Namen tovrstne avtomatizacije je zmanjšati število ročnih posegov, ki so pod-

vrženi napakam, in zagotoviti, da se aplikacija v vseh okoljih obnaša enako, ne glede na razlike v konfiguraciji računalnika ali strežnika [42]. Tak pristop temelji na načelu usklajenosti okolij (angl. *environment parity*), po katerem naj bodo razvojno, testno in produkcijsko okolje čim bolj podobna, s čimer zmanjšamo tveganje za napake, ki se pojavijo šele ob namestitvi [83].

4.8.1 Postavitev razvojnega okolja z vsebniki

Za vsebnikizacijo razvojnega okolja smo uporabili orodje Docker Compose [17], ki omogoča enostavnejšo vzpostavitev več med seboj povezanih vsebnikov. Orodje deluje tako, da v datoteki `docker-compose.yml` opišemo vse potrebne storitve in njihove medsebojne odvisnosti, kar omogoča zagon celotnega okolja z enim samim ukazom. To je še posebej uporabno pri razvoju in testiranju. Za lokalno preizkušanje pošiljanja elektronske pošte smo uporabili orodje MailHog [49], ki odhodno pošto prestreže in jo prikaže v spletnem vmesniku, brez dejanskega pošiljanja na pravi naslov. Za zaledni sistem in sistem za vrednotenje vozil smo napisali ločeni datoteki `Dockerfile`, v katerih določimo, jezik ter okolje sistema ter katere ukaze naj vsebnik ob zagonu izvede.

Ker se storitve med seboj zaganjajo z različnimi hitrostmi, smo za pravilno zaporedje zagona uporabili `depends_on` v kombinaciji z definicijami `healthcheck`. Brez tega bi se zaledni sistem lahko poskusil prezgodaj povezati s podatkovno bazo, kar bi ob zagonu okolja povzročilo napako. Odvisne storitve, zato vsebujejo ukaz za preverjanje pripravljenosti (`pg_isready` pri sistemu PostgreSQL oziroma `redis-cli ping` pri sistemu Redis [69]) in se zaženejo šele, ko je preverjanje uspešno.

Za shranjevanje podatkov smo uporabili poimenovane nosilce podatkov (angl. *named volumes*): prvi skrbi za trajnost podatkovne baze med ponovnimi zagoni vsebnikov, drugi pa predpomni mapo `node_modules` znotraj zalednega vsebnika, saj bi jo sicer prepisala mapa gostitelja. Za osveževanje ob spremembah (angl. *hot reload*), uporabljamo prevezavo map (angl. *bind mount*) iz gostiteljevega datotečnega sistema v vsebnik, tako da se spremembe v izvorni kodi takoj odražajo v delovanju aplikacije.

Odjemalskega sistema v lokalno razvojno okolje namenoma nismo vključili, saj njegova vključitev zaradi nenehnih ponovnih izgradenj slike ob vsaki spremembi bistveno upočasni razvoj. Med razvojem, ga tako poganjamo neposredno na gostitelju.

Za produkcijsko okolje uporabljamo ločeno datoteko `docker-compose.prod.yml`, ki namesto lokalne gradnje slik uporablja vnaprej zgrajene slike iz registra vsebnikov (angl. *container registry*). Storitve poveže v skupno omrežje ter doda poimenovan nosilec podatkov za shranjevanje naloženih datotek.

4.8.2 Neprekinjena integracija

Neprekinjena integracija (angl. *continuous integration*) je praksa, pri kateri se ob vsaki spremembi kode samodejno izvedejo preverjanja (testiranje, izgradnja, statična analiza kode). Na ta način napake odkrijemo, še preden se zlijejo v glavno vejo ali dosežejo druge razvijalce [23]. Namesto ročnega testiranja razvijalca pred združitvijo sprememb, teste izvede strežnik, vedno na enak način.


Za implementacijo neprekinjene integracije smo uporabili orodje GitHub Actions [27]. Njegovo delovanje opredeljujejo nadlednji pojmi:

- **Potek dela** (angl. *workflow*) je določen v datoteki `.yml` v mapi `.github/workflows/`, ki določa, kdaj naj se (npr. ob dogodku `pull_request` ali `push`) sprožijo določena opravila.
- **Opravilo** (angl. *job*) se izvede na svežem virtualnem strežniku (npr. `ubuntu-latest`), ki ga GitHub ob zagonu ustvari in po zaključku izbriše.
- **Koraki** (angl. *steps*) znotraj opravila so zaporedni ukazi. To so lahko neposredni lupinski ukazi (npr. `run: npm test`) ali vnaprej pripravljeni in ponovno uporabni gradniki (angl. *actions*), ki jih razvije GitHub ali skupnost. Tako gradnik `actions/checkout` prenese izvirno kodo, gradnik `pnpn/action-setup` pa namesti upravitelja paketov. Na-

mesto lastnoročno napisane skripte (za namestitev okolja Node, predpomenjenje odvisnosti in nastavitve spremenljivke `PATH`) tako uporabimo že obstoječi gradnik.

- **Storitve** (angl. *services*) so pomožni vsebniki, ki tečejo vzporedno z opravilom. Uporabni so, takrat ko testi potrebujejo pravo podatkovno bazo namesto njene simulacije (angl. *mock*).

Potek dela v datoteki `ci.yml`, smo določili tako, da se ob vsakem novem zahtevku za združitev (angl. *pull request*) izvedejo vsi testi zalednega sistema ob tem se preveri, ali se uspešno izvedejo. Potek dela v datoteki `docker-publish.yml` je zasnovan še korak dlje: ob zahtevku za združitev se zgolj preveri, ali se slika Docker uspešno zgradi, ob združitvi v glavno vejo pa se sliko tudi dejansko zgradi, digitalno podpiše in objavi. Ta korak že sodi na področje neprekinjene dostave (angl. *continuous delivery*), torej samodejne distribucije zgrajene programske rešitve [33]. V naslednji sliki je prikazan primer izgradnje in izvajanja testov na cevovodu 4.9.



Slika 4.9: Samodejno izvajanje testov nad vejo na cevovodu


4.8.3 Namestitev in gostovanje

Za gostovanje smo izbrali eno izmed cenovno najugodnejših možnosti in sicer najeti navidezni zasebni strežnik (angl. *virtual private server*) pri ponudniku

Hetzner [32]. Strežnik razpolaga s 4 GB delovnega pomnilnika in dvema procesorskima jedroma, kar zadostuje za zagon vseh treh storitev. Po prvi prijavi v strežnik smo najprej posodobili operacijski sistem na najnovejšo različico, nato pa namestili orodji Docker in Docker Compose.

Za upravljanje aplikacije smo uporabili orodje Dokploy [18], ki omogoča enostavno uporabo datotek `docker-compose` v produkcijskem okolju in hkrati močno poenostavi postopek posodabljanja aplikacije. V njem lahko nastavimo tudi opravila, ki se izvajajo periodično, (podobno kot storitev `cron`). Na strežnik je treba namestiti še povezovalno komponento med orodjema Dokploy in Docker, nato pa Dokploy sam poskrbi za izgradnjo aplikacije: iz repozitorija GitHub zajame najnovejšo različico kode in zgradi pripadajočo sliko neposredno na strežniku. Tak postopek omogoča, da se vsaka sprememba v produkcijskem okolju odrazi v nekaj minutah.

Dokploy je odprtokodno in brezplačno orodje, najem strežnika pri ponudniku Hetzner pa predstavlja nizek mesečni strošek (trenutno 6.50€ na mesec). Levo na sliki 4.10 je upravljalna stran Hetzner, desno je pa uporabniški vmesnik Dokploy.



Slika 4.10: Upravljalna stran Hetzner in Dokploy

Poglavje 5

Analiza in vrednotenje rešitve

V tem poglavju sistematično pregleadamo in analiziramo razvito rešitev. Najprej iz zahtev in izhodišč, ki smo si jih zastavili na začetku, izpeljemo raziskovalna vprašanja in za vsako določimo merilo uspešnosti (razdelek 5.1). Nato opišemo merilno okolje in postopke (razdelek 5.2) ter natančno definiramo vse uporabljene mere (razdelek 5.3). Sledijo rezultati: značilnosti zbranih podatkov (5.4), natančnost ocene vrednosti (5.5), občutljivost algoritma na parametre (5.6), latenca posameznega vrednotenja (5.7) in obnašanje pod obremenitvijo (5.8). Zatim preverimo funkcionalne in nefunkcionalne zahteve (5.9, 5.10) ter predstavimo uporabniški preizkus (5.11) in simulacijo uporabe (5.12). Poglavje sklenemo z obravnavo groženj veljavnosti (5.13) in povzetkom ugotovitev glede na zastavljena izhodišča (5.14).

5.1 Raziskovalna vprašanja in merila uspešnosti

Na začetku diplomskega dela (poglavje 1) smo si zastavili, da je mogoče uporabniku na podlagi zbranih tržnih podatkov in primerjave s podobnimi vozili ponuditi *uporabno* in *dovolj natančno* oceno tržne vrednosti vozila in da vključitev takega sistema izboljša uporabniško izkušnjo. Iz tega izhodišča in iz nefunkcionalnih zahtev (razdelek 4.1) izpeljemo štiri raziskovalna vprašanja

(RV1–RV4) in za vsako določimo merilo uspešnosti.

Mediana absolutne odstotne napake (MdAPE) je osrednja mera natančnosti v tem poglavju; nanjo se sklicujejo merila uspešnosti in vsi nadaljnji razdelki. Izračunamo jo tako, da za vsak testni primer določimo absolutno odstotno napako, torej za koliko odstotkov se ocenjena cena razlikuje od dejanske, nato pa čez vse primere vzamemo mediano teh vrednosti. MdAPE = 15 % tako pomeni, da je pri polovici vozil ocena znotraj 15 % od dejanske cene, pri drugi polovici pa je odstopanje večje; manjša kot je vrednost, natančnejše so ocene. Mediano uporabljamo namesto povprečja, ker je manj občutljiva na posamezne skrajne napake. Natančne definicije MdAPE in preostalih mer so v razdelku 5.3.

Raziskovalna vprašanja so:

- **RV1 — natančnost ocene.** Kako natančno sistem oceni tržno vrednost vozila v primerjavi z dejanskimi oglasi na trgu? *Merilo:* MdAPE je pri vozilih z vsaj 10 primerljivimi vozili manjša od 15 %, ocena pa je bistveno natančnejša od preproste (naivne) referenčne metode.
- **RV2 — odvisnost natančnosti od podatkov.** Od česa je natančnost ocene najbolj odvisna (velikost vzorca primerljivih vozil, razpršenost ponudbe, segment vozila)?
- **RV3 — hitrost in razširljivost.** Ali sistem zadošča nefunkcionalnim zahtevam glede odzivnosti tudi pod sočasno obremenitvijo, in kje je zgornja meja trenutne postavitve?
- **RV4 — uporabnost.** Ali ciljni uporabniki znajo brez navodil opraviti glavne naloge (registracija, objava oglasa, vrednotenje)?

5.2 Metodologija in merilno okolje

Merilno okolje. Meritve hitrosti (razdelka 5.7 in 5.8) so izvedene v *produkcijskem* okolju, torej na navideznem zasebnem strežniku z dvema proce-

sorskima jedroma in 4 GB pomnilnika ter s tehnologijami in njihovimi različicami, opisanimi v poglavju 4 (razdelek 4.8.3). Analitične in merilne skripte tečejo nad isto podatkovno bazo kot je na produkciji.

Posnetek podatkov. Meritve v tem poglavju temeljijo na posnetku podatkovne baze iz septembra 2026, ki obsega približno 86.000 normaliziranih oglasov (razdelek 5.4). Ker se posnetek med analizo ne spreminja, so rezultati ponovljivi.

Orodja. Za meritve in analizo v tem poglavju smo napisali namenske skripte, ločene od produkcijske kode; ena od njih je dokumentirana kopija ocenjevalnega algoritma, parametrizirana za eksperimente. Statistično obdelavo in izris grafov smo izvedli s knjižnicama `NumPy` [30] in `Matplotlib` [34].

Natančnost. Natančnost ocene (razdelek 5.5) merimo z naključno izbranim normaliziranim oglasom: njegove attribute (znamka, model, letnik, kilometrina) uporabimo kot vhod v algoritem, sam oglas pa izločimo iz primerjalne množice. Nato izračunamo oceno in jo primerjamo z *dejansko oglaševano* ceno tega oglasa. Postopek ponovimo za 3000 naključnih oglasov.

5.3 Uporabljene mere

Latenca je čas, ki preteče od trenutka tik pred oddajo zahtevka do trenutka, ko odjemalec prejme celoten odgovor. Glede na to, kolikšen del te poti zajamemo, ločimo tri vrste:

- (a) *latenca obdelave na strežniku* — čas izvajanja funkcije za vrednotenje, od začetka do konca, brez omrežja;
- (b) *latenca poizvedbe SQL* — čas izvajanja poizvedbe v podatkovni bazi, od začetka do konca, brez omrežja;

- (c) *latenca od konca do konca* (angl. *end-to-end*) — (a) skupaj z omrežnim obhodom med odjemalcem in strežnikom ter obdelavo zahtevka HTTP; to je čas, ki ga zazna uporabnik.

V razdelku 5.7 merimo vrsti (a) in (b), v razdelku 5.8 pa vrsto (c).

Percentili. **Percentil** p_k je vrednost, pod katero pade $k\%$ meritev. Poročamo p_{50} (mediana), p_{95} in p_{99} .

Prepustnost, sočasnost, nasičenje. Obnašanje sistema pod obremenitvijo opišemo s tremi količinami:

- **prepustnost** — število uspešno obdelanih zahtevkov na sekundo;
- **sočasnost** — število odjemalcev, ki hkrati držijo odprt zahtevek;
- **nasičenje** (*koleni*) — točka, v kateri dodatna sočasnost ne poveča več prepustnosti, latenca pa začne naraščati približno linearno.

Notranjo skladnost meritev preverimo z **Littlovim zakonom** [48],

$$L = \lambda \cdot W, \quad (5.1)$$

kjer je L povprečno število zahtevkov v sistemu, λ prepustnost in W povprečna latenca.

Napaka ocene. Za oglas i z dejansko ceno p_i in ocenjeno ceno $\hat{p}_i$ definiramo absolutno odstotno napako

$$\text{APE}_i = \frac{|\hat{p}_i - p_i|}{p_i}. \quad (5.2)$$

MAPE je povprečje APE_i , **MdAPE** pa njihova mediana; MdAPE je robustnejša na osamelce in je naša glavna mera [35]. Poročamo tudi **MAE** (povprečna absolutna napaka) in **RMSE** (koren povprečne kvadratne napake) v evrih ter *predznačeno* odstotno napako, ki pokaže sistematičen odmik ocene navzgor ali navzdol.

Pokritost. **Pokritost** je delež poizvedb, za katere sistem vrne oceno, torej za katere najde vsaj eno (oziroma vsaj 5 oz. 10) primerljivo vozilo.

Raznolikost ponudbe. **Raznolikost** (v izvorni kodi `ratio`) je relativna širina cenovnega razpona primerljivih vozil,

$$\text{raznolikost} = \frac{P_{75} - P_{25}}{\hat{p}}, \quad (5.3)$$

kjer sta P_{25} in P_{75} (v kodi `goodPrice` in `badPrice`) uteženi 25. oziroma 75. percentil cen primerljivih vozil, $\hat{p}$ (v kodi `estimatedPrice`) pa ocenjena cena vozila. Vrednost izražamo v odstotkih; enoten zapis uporabljamo v vseh tabelah tega poglavja.

5.4 Značilnosti zbranih podatkov

Viri in obseg. Velika večina oglasov je bila zajeta z največjega slovenskega spletnega portala za prodajo rabljenih vozil (razdelek 3.2); manjši del predstavlja vzorec z večjega nemškega oglasnega portala, ki smo ga uporabili za preverjanje delovanja cevovoda na drugačni strukturi vira. Zajem je zajel javno dostopne oglase za nekomercialno raziskovalno rabo, z omejeno hitrostjo zahtevkov in brez shranjevanja kontaktnih ali osebnih podatkov prodajalcev. Po normalizaciji baza obsega 85.846 oglasov (83.493 s slovenskega in 2.353 z nemškega portala) za 10 znamk vozil; razčlenitev po znamki je v tabeli 5.1.

Porazdelitve ključnih atributov. Slika 5.1 prikazuje porazdelitve oglaševanih cen, prevožene kilometrine in letnika. Porazdelitev cen je izrazito desno asimetrična (dolga rep dragih vozil), zato jo prikazujemo na logaritemski osi. Mediana cene je 14.890 EUR (povprečje 18.137 EUR), mediana kilometrine 159.950 km, mediana letnika pa 2017; podrobnosti so v tabeli 5.2. Zaradi berljivosti so na grafih odrezane skrajne vrednosti (nekaj oglasov ima očitno napačno ceno, kilometrino ali letnik); njihovo število je označeno v kotu vsa-

Tabela 5.1: Število normaliziranih oglasov po znamki.

Znamka	Oglasi	Znamka	Oglasi
Volkswagen	21.191	Peugeot	7.513
Audi	11.842	Citroën	6.729
BMW	10.724	Ford	5.783
Renault	9.615	Toyota	2.648
Mercedes-Benz	9.355	Alfa Romeo	446


kega grafa, celoten razpon pa je razviden iz stolpca *maks.* v tabeli 5.2 in iz obravnave osamelcev v tabeli 5.3.

Tabela 5.2: Povzetek porazdelitev ključnih numeričnih atributov.


	p_5	mediana	povprečje	p_{95}	maks.
cena [EUR]	1.550	14.890	18.137	49.014	374.000
kilometrina [km]	26.000	159.950	169.464	334.000	1.974.001
letnik	2005	2017	2016	2024	2029
moč [kW]	56	110	117	221	920

Pokritost po segmentih. Za pošteno oceno mora imeti algoritem dovolj primerljivih vozil v ožjem segmentu (ista znamka in model, podoben letnik in kilometrina). Slika 5.2 prikazuje toplotno karto za znamki Renault in Volkswagen: vrstice so modeli, stolpci letniki, barva pa število oglasov v tej kombinaciji. Vidno je, da so pogosti modeli srednjih letnikov (npr. Volkswagen Golf ali Renault Clio) gosto pokriti, redki modeli in skrajni letniki pa le redko, kar neposredno pojasni razlike v zanesljivosti ocen (razdelek 5.5).


Osamelci in kakovost podatkov. Postopek normalizacije trenutno ne izvaja filtriranja osamelcev, zato baza vsebuje tudi vozila z očitno napačnimi vrednostmi. Tabela 5.3 prikazuje njihov delež. Kar 10,7% oglasov ima vsaj




(a) oglaševana cena (log)



(b) prevoženi kilometri




(c) letnik prve registracije



(d) oglasi po znamki

Slika 5.1: Porazdelitve ključnih atributov v normalizirani bazi.



Slika 5.2: Pokritost: število oglasov po modelu in letniku za znamki Renault in Volkswagen (po ena znamka na vrstico).

eno vrednost zunaj smiselnih mej, največ pri kilometrini (9,9 %; najvišja za-
beležena vrednost je skoraj dva milijona kilometrov) in letniku (8,1 %; nekaj
oglasov ima celo letnik v prihodnosti). Preprost filter po interkvartilnem raz-
ponu (IQR) na ceni znotraj skupine (znamka, model) bi odstranil dodatnih
2,2 % oglasov. Vpliv doslednega filtriranja osamelcev na natančnost obravna-
vamo v razdelku 5.6, uvedbo takega filtra pa v poglavju 6.

Tabela 5.3: Osamelci v normalizirani bazi (85.846 oglasov).

Merilo	Št. vrstic	Delež
cena zunaj [500, 200.000] EUR	427	0,5 %
kilometrina zunaj [1000, 500.000] km	8.495	9,9 %
letnik zunaj [1990, 2027]	6.979	8,1 %
vsaj ena vrednost zunaj mej	9.169	10,7 %
dodatno po filtru IQR na ceni	1.878	2,2 %


5.5 Natančnost ocene vrednosti

To je osrednja meritev diplomskega dela: neposredno preverja zastavljeno iz-
hodišče o *dovolj natančni* oceni (RV1). Protokol je opisan v razdelku 5.2,
rezultate pa izdela skripta `analysis/accuracy_cv.py` nad vzorcem 3000
oglasov (od tega jih je 2986 dobilo oceno).

Merilo resnice in namerni odmik ocene. Kot merilo resnice upora-
bljamo *oglaševano* ceno, saj dejanske prodajne cene niso javno dostopne. Sis-
tem pa namenoma ne ocenjuje oglaševane cene, temveč *pričakovano prodajno*
ceno: ker se rabljena vozila v pogajanjih praviloma prodajo pod oglaševano
ceno, oceno zniža s stopenjskim popustom (9–15 % glede na cenovni razred).
Zato je pri primerjavi z oglaševano ceno pričakovan rahel *negativni* odmik
ocene, kar je zaželeno in ne pomeni slabše ocene. To lastnost upoštevamo
pri branju vseh rezultatov v nadaljevanju: napako merimo dvakrat — proti

oglaševani ceni z vključenim popustom (kar dejansko vrne sistem) in brez popusta (čista primerjalna ocena).

Skupni rezultat. Brez popusta znaša MdAPE predlaganega pristopa 13,5 %, MAPE 23,8 %, MAE 2798 EUR in RMSE 5151 EUR; z vključenim namernim popustom je MdAPE proti oglaševani ceni 14,5 % (mediana predznačene napake $-6,8\%$). Pokritost je 99,5 % pri $n \geq 1$ in 95,7 % pri $n \geq 10$. Slika 5.3a prikazuje napovedano ceno proti dejanski ($R^2 = 0,87$), slika 5.3b pa porazdelitev odstotne napake.




Slika 5.3: Natančnost ocene vrednosti (leave-one-out, brez popusta).

Primerjava z osnovnimi modeli. Da presodimo, ali je predlagani pristop boljši od trivialnega, ga primerjamo s štirimi referenčnimi modeli na istem protokolu in isti množici kandidatov (tabela 5.4, slika 5.4): B0 globalna mediana cene za dani model, B1 navadno povprečje cen v filtrirnem oknu, B1m mediana cen v oknu, B2 linearna regresija $\text{cena} \sim \text{letnik} + \text{km}$, B3 metoda k najbližjih sosedov ($k = 10$) po standardiziranih letniku in kilometri, ter B4 naš pristop (uteženo povprečje s podobnostnim jedrom, brez popusta).

Predlagani pristop je *bistveno* boljši od naivne globalne mediane (13,5 % proti 37,8 %) in primerljiv s preostalimi metodami, ki se gibljejo med 11 in 14 %. Ni pa najboljši: metoda k najbližjih sosedov doseže 11,2 %, tudi

Tabela 5.4: Primerjava natančnosti z osnovnimi modeli (leave-one-out). MdAPE in MAPE sta v odstotkih, MAE in RMSE v evrih.


Model	MdAPE	MAPE	MAE	RMSE
B0 globalna mediana	37,8	95,7	7395	10883
B1 povprečje v oknu	14,2	24,9	2930	5333
B1m mediana v oknu	13,1	22,5	2877	5561
B2 linearna regresija	12,9	22,4	2677	5032
B3 k -najbližjih sosedov	11,2	21,5	2497	4883
B4 naš pristop	13,5	23,8	2798	5151



Slika 5.4: MdAPE osnovnih modelov in predlaganega pristopa.

navadna mediana istega okna (13,1 %) je malenkost natančnejša. To je pričakovano za zasnovu, katere cilj je *razložljivost*: za razliko od naštetih metod predlagani pristop poleg točkovne ocene vrne tudi cenovni razpon in indeks zaupanja, uteži pa so neposredno interpretabilne. Rezultat hkrati potrjuje smiselnost prehoda na metode strojnega učenja, ki jo predlagamo v poglavju 6: če že preprost k -NN preseže sedanji pristop, je od zmogljivejših modelov mogoče pričakovati še boljše rezultate.

Odvisnost od velikosti vzorca in segmenta (RV2). Slika 5.5a prikazuje MdAPE glede na število primerljivih vozil n : napaka je pri $n < 10$ okoli 20 %, pri $n \geq 20$ pa se ustali pri približno 13 %. To empirično podpira izbiro konstante 20 v indeksu zaupanja (enačba 4.2) — pri toliko primerljivih vozilih je ocena že blizu svoje najboljše natančnosti. Slika 5.5b prikazuje MdAPE po znamki: najboljše se odrežejo pogosti, gosto pokriti modeli (Audi 9,8 %, Toyota 10,8 %, Volkswagen 12,1 %), najslabše pa Mercedes-Benz (24,9 %), pri katerem se pri normalizaciji več različnih modelov zlije v isto kanonično ime, kar poslabša izbor primerljivih vozil. Tabela 5.5 kaže še razčlenitev po starosti, kilometrini in raznolikosti ponudbe.



Slika 5.5: Odvisnost natančnosti ocene od podatkov.


Vzorec pokaže jasne zakonitosti: napaka narašča s starostjo vozila (9 % pri najnovejših, 23 % pri vozilih, starejših od 13 let), s prevoženo kilometrino

Tabela 5.5: Natančnost predlaganega pristopa po segmentih (MdAPE).

Razčlenitev	Koš	Primeri	MdAPE [%]
starost [leta]	0–3	367	9,0
	4–7	921	10,6
	8–12	932	14,5
	13+	766	22,9
kilometrina	< 50.000	280	9,6
	50.000–100.000	449	11,9
	100.000–150.000	634	12,4
	150.000–200.000	629	13,7
	> 200.000	1021	16,7
raznolikost	0–0,10	88	7,5
	0,10–0,25	1002	8,4
	0,25–0,50	1613	15,5
	> 0,50	447	29,7

in — najmočnejše — z *raznolikostjo ponudbe*. Pri modelih z enotno ponudbo (raznolikost pod 0,1) je MdAPE le 7,5 %, pri razpršeni ponudbi (nad 0,5) pa 29,7 %. To potrjuje, da je raznolikost, ki jo sistem uporabniku tudi prikaže, dober vgrajen pokazatelj zanesljivosti posamezne ocene.

Vpliv popusta. Slika 5.6 prikazuje predznačeno napako z in brez popusta. Brez popusta je ocena rahlo optimistična (mediana +3,8 % nad oglaševano ceno), z namernim popustom pa se premakne na −6,8 % pod oglaševano ceno. Ta premik je skladen z zasnovo sistema, ki cilja pričakovano prodajno in ne oglaševane cene; dokončno umerjanje popusta bi bilo mogoče šele s podatki o dejanskih prodajah (razdelek 5.13).



Slika 5.6: Predznačena napaka proti oglaševani ceni, z in brez namernega popusta.

Časovni razrez. Pri napovedovanju najnovejših 10 % oglasov zgolj iz starejših 90 % znaša MdAPE predlaganega pristopa 13,0 % (tabela 5.6), kar je celo malenkost bolje od rezultata leave-one-out in potrjuje, da ocena ne izhaja iz uhajanja informacije.

Tabela 5.6: Natančnost pri časovnem razrezu (napoved najnovejših 10 %). MdAPE in MAPE sta v odstotkih, MAE in RMSE v evrih.

Model	MdAPE	MAPE	MAE	RMSE
B0 globalna mediana	35,9	74,5	7596	11222
B1m mediana v oknu	12,8	19,7	3088	5805
B3 k -najbližjih sosedov	10,5	18,2	2667	4890
B4 naš pristop	13,0	20,6	2994	5347

5.6 Občutljivost algoritma na parametre


Ocenjevalni algoritem vsebuje več hevristično določenih konstant: dovoljeno odstopanje kilometrine (± 40.000 km) in letnika (± 3 leta), uteži delnih ocen (0,6 in 0,4), oblika padajoče funkcije in stopenjski popust. V tem razdelku vsako spreminjamo ob nespremenjenih ostalih in merimo MdAPE ter pokritost (vzorec 2000 oglasov, leave-one-out). Rezultate izdela skripta `analysis/sensitivity.py`.

Okno primerljivosti. Tabela 5.7 in slika 5.7 kažeta, da je algoritem na širino *kilometrinskega* okna skoraj neobčutljiv: MdAPE se med ± 10.000 km in ± 80.000 km giblje le med 13,2 in 13,6 %. Nasprotno je odvisen od *letnikovega* okna: pri ± 1 letu je MdAPE 12,6 %, pri ± 5 letih pa 15,2 %. Ožje okno da bolj primerljiva vozila, a manjši vzorec (nižja pokritost); gre za znano razmerje med pristranskostjo in varianco [31]. Toplotna karta (slika 5.8) potrjuje, da natančnost določa skoraj izključno letnikovo okno. Sedanja izbira ± 3 leta je razumen kompromis med natančnostjo in pokritostjo; morebitna zožitev na ± 2 leti bi MdAPE znižala za približno 0,3 odstotne točke ob še vedno visoki pokritosti.


Uteži, oblika jedra in popust. Tabela 5.8 povzema preostale parametre. Razmerje uteži med kilometrino in letnikom na natančnost praktično ne vpliva (13,4 do 13,6 % za vsa preizkušena razmerja), prav tako ne zamenjava linearne padajoče funkcije z eksponentno (13,4 proti 13,3 %). Edina

Tabela 5.7: Občutljivost na širino okna primerljivosti. Pokritost je delež poizvedb z vsaj 5 primerljivimi vozili.

Parameter	MdAPE [%]	Pokritost [%]	Mediana n
kilometrina ± 10.000 km	13,2	92,3	53
kilometrina ± 40.000 km	13,4	98,1	196
kilometrina ± 80.000 km	13,6	99,0	362
letnik ± 1 leto	12,6	95,6	97
letnik ± 3 leta	13,4	98,1	196
letnik ± 5 let	15,2	98,5	262




(a) okno kilometrine



(b) okno letnika

Slika 5.7: Občutljivost na širino okna primerljivosti (MdAPE in pokritost).



Slika 5.8: MdAPE [%] po mreži dovoljenih odstopanj kilometrine in letnika.

parametra, ki opazno premakneta rezultat, sta torej širina letnikovega okna in namerni popust: ta predznačeno napako proti oglaševani ceni premakne iz $+3,8\%$ v $-6,8\%$, MdAPE pa zviša z $13,4$ na $14,5\%$. Ta premik je posledica zavestne odločitve, da sistem ocenjuje pričakovano prodajno in ne oglaševane cene, in ne slabše ocene.

Tabela 5.8: Občutljivost na uteži, obliko jedra in popust.

Parameter	Nastavitev	MdAPE [%]	Predznačena napaka [%]
uteži (km / letnik)	0,5/0,5	13,4	+3,7
uteži (km / letnik)	0,6/0,4 (privzeto)	13,4	+3,8
uteži (km / letnik)	0,8/0,2	13,6	+3,8
jedro	linearno (privzeto)	13,4	+3,8
jedro	eksponentno	13,3	+3,8
popust	brez	13,4	+3,8
popust	stopenjski (privzeto)	14,5	-6,8

Sklep o robustnosti. Algoritem je robusten: na večino svojih konstant se skoraj ne odziva, kar pomeni, da njihova hevristična izbira ni sporna. Njegova natančnost je odvisna predvsem od kakovosti in gostote podatkov (razdelek 5.5), ne od finega nastavljanja parametrov.

5.7 Latenca posameznega vrednotenja

Merimo latenco vrste (a) in (b) iz razdelka 5.3. Meritev izvede `benchmarks/bench_algo.py`: 2000 neposrednih klicev funkcije nad naključnimi realnimi vhodi (brez HTTP), po 100 ogrevalnih klicih, ki se ne merijo. Ločeno merimo čas poizvedbe SQL, čas točkovanja v Pythonu in čas serializacije odgovora.

Ozko grlo: pregled celotne tabele. Prvotna izvedba poizvedbe ni imela ustreznega indeksa. Izsek 8 prikazuje izpis `EXPLAIN (ANALYZE, BUFFERS)`: načrt je `Seq Scan`, baza pri vsakem vrednotenju prebere celotno tabelo in zavrže 85.273 vrstic, ki ne ustrezajo pogojem (`Rows Removed by Filter`). Ker so podatki v celoti v predpomnilniku (`shared hit`, brez `read`), je čas stabilen, a raste linearno z velikostjo tabele.

Izsek kode 8: `EXPLAIN (ANALYZE, BUFFERS)` pred dodajanjem indeksa.


```
1 Seq Scan on normalized_market_listing
2   (cost=0.00..3314.15 rows=12 width=97)
3   (actual time=0.555..6.847 rows=573 loops=1)
4   Filter: ((kilometers >= 18500) AND (kilometers <= 98500)
5           AND (registration_year >= 2019) AND (registration_year <= 2025)
6           AND (brand_name = 'Citroën') AND (model_name = 'C3'))
7   Rows Removed by Filter: 85273
8   Buffers: shared hit=1168
9 Execution Time: 6.880 ms
```

Učinek sestavljenega indeksa. Po dodajanju sestavljenega indeksa na (`brand_name`, `model_name`, `registration_year`, `kilometers`) se načrt spremeni v `Bitmap Index Scan` (izsek 9): baza prebere le nekaj strani indeksa

in pripadajoče vrstice, čas izvajanja pa pade z 6,88 ms na 0,69 ms. Latenca poizvedbe SQL se v mediani zmanjša z 9,7 ms na 2,0 ms (tabela 5.9, slika 5.9). Pomembneje od trenutnega pohitrenja je, da postane čas poizvedbe neodvisen od velikosti tabele: namesto $O(\text{tabela})$ postane $O(\text{zadetki})$.

Tabela 5.9: Latenca poizvedbe SQL pred in po dodajanju indeksa, v milisekundah.

	p50	p95	p99	Povprečje
pred (Seq Scan)	9,7	21,0	24,8	11,3
po (Index Scan)	2,0	8,6	12,5	3,0



Slika 5.9: Latenca poizvedbe SQL pred in po dodajanju sestavljenega indeksa.

Izsek kode 9: EXPLAIN (ANALYZE, BUFFERS) po dodajanju indeksa.

```

1 Bitmap Heap Scan on normalized_market_listing
2   (cost=5.84..50.49 rows=12 width=97)
3   (actual time=0.202..0.615 rows=573 loops=1)
4   Recheck Cond: (brand_name = 'Citroën' AND model_name = 'C3'
5     AND registration_year BETWEEN 2019 AND 2025
6     AND kilometers BETWEEN 18500 AND 98500)

```

```

7   Buffers: shared hit=195
8   -> Bitmap Index Scan on idx_nml_valuation
9       (actual time=0.166..0.166 rows=573 loops=1)
10      Buffers: shared hit=6
11 Execution Time: 0.688 ms

```

Razčlenitev latence po komponentah. Tabela 5.10 in slika 5.10 prikazujeta latenco celotnega vrednotenja po dodajanju indeksa. Tipično vrednotenje traja 2,0 ms, v najslabšem odstotku primerov (p99) pa 13,5 ms. Skoraj celotna latenca ($\approx 88\%$ povprečja) odpade na poizvedbo SQL; točkovanje v Pythonu (0,4 ms povprečno) in serializacija odgovora ($\approx 0,01$ ms) sta zanemarljiva. Poizvedba v povprečju vrne 287 primerljivih vozil (mediana 175, največ 1495).


Tabela 5.10: Latenca posameznega vrednotenja po dodajanju indeksa ($N = 2000$), v milisekundah.

Komponenta	p50	p95	p99	Povprečje
Skupaj	2,0	9,7	13,5	3,1
Poizvedba SQL	1,8	8,4	11,5	2,7
Točkovanje (Python)	0,2	1,2	1,8	0,4
Serializacija (JSON)	0,01	0,02	0,03	0,01

Vrednotenje se torej izvede daleč pod nefunkcionalno zahtevo 2 s (razdelek 4.1); prostora za rast podatkovne baze je ob prisotnosti indeksa dovolj.

5.8 Obnašanje pod obremenitvijo

Merimo end-to-end latenco (vrsta (c)) in prepustnost končne točke POST /*evaluate* pri naraščajoči sočasnosti. Obremenitev ustvarja skripta `benchmarks/loadtest.py` z več vzporednimi odjemalci, ki v fiksnem 20-sekundnem oknu neprekinjeno pošiljajo zahteve z naključnimi realnimi vhodi. Test se samodejno prekine



Slika 5.10: Razčlenitev latence posameznega vrednotenja po komponentah.

ob deležu napak nad 5 % ali p_{95} nad 5 s. Med testom vzorčimo tudi zasedenost baze (`pg_stat_activity`).

Tabela 5.11: Prepustnost in latenca pri naraščajoči sočasnosti. Latence so v milisekundah, L je ocena po Littlovem zakonu.

Sočasnost	Prep. [z/s]	p50	p95	p99	Napake	L
1	[x]	[x]	[x]	[x]	[x]	[x]
5	[x]	[x]	[x]	[x]	[x]	[x]
10	[x]	[x]	[x]	[x]	[x]	[x]
20	[x]	[x]	[x]	[x]	[x]	[x]
40	[x]	[x]	[x]	[x]	[x]	[x]

Rezultat. [Prepustnost narašča približno linearno do sočasnosti X , nato se ustali pri približno X zahtevkih na sekundo. Vse latence ostanejo pod nefunkcionalno zahtevo 2 s.]

Skladnost meritve (Littlov zakon). [Stolpec L (prepustnost krat povprečna latenca) ostaja blizu nastavljenе sočasnosti, kar potrjuje notranjo skladnost meritve.]

Dokaz ozkega grla. Teoretični strop postavitve je $1000/S \approx 324$ vrednotenj na sekundo, kjer je $S = 3,1$ ms povprečni čas ene evalvacije. Dejanska meja je nižja, ker ves promet serializira *ena sama deljena povezava do baze* (`app/database.py`) in en sam strežniški proces. **[To potrjuje vzorčenje baze med testom: število aktivnih poizvedb kljub naraščajoči soča-
snosti odjemalcev ne preseže X.]**

5.9 Preverjanje funkcionalnih zahtev

Tabela 5.12 povezuje vsako funkcionalno zahtevo iz razdelka 4.1 z načinom preverjanja in izidom.

Tabela 5.12: Sledljivost funkcionalnih zahtev do preverjanja.

Zahteva	Način preverjanja	Izid
Registracija uporabnika	[test / scenarij]	[OK]
Prijava in odjava	[test / scenarij]	[OK]
Objava oglasa (le registrirani)	[test / scenarij]	[OK]
Vrednotenje vozila po atributih	[test / scenarij]	[OK]
Všečkanje oglasov	[test / scenarij]	[OK]
Ažuriranje lastnih/všečkanih oglasov	[test / scenarij]	[OK]
Pregled oglasov (anonimni)	[test / scenarij]	[OK]

Pokritost testov. Avtomatizirani testi zalednega sistema (Jest + Super-test, razdelek 4.3.3) obsegajo [X] testov v [X] zbirkah in pokrivajo [X] % stavkov ter [X] % vej. Testi se izvedejo ob vsakem zahtevku za združitev na cevovodu neprekinjene integracije (razdelek 4.8.2).

5.10 Preverjanje nefunkcionalnih zahtev

Tabela 5.13 za vsako nefunkcionalno zahtevo iz razdelka 4.1 navaja merilo, izmerjeno vrednost in sodbo.

Tabela 5.13: Preverjanje nefunkcionalnih zahtev.

Zahteva	Merilo	Izmerjeno	Sodba
Odziv vmesnika na dejanje uporabnika	< 100 ms	[x] ms	[OK]
Zahtevki HTTP (razen vrednotenja)	< 300 ms	[x] ms (p_{95})	[OK]
Vrednotenje vozila	< 2 s	13,5 ms (p_{99} , brez omrežja)	OK
Vizualna privlačnost / dostopnost	Lighthouse	[x] / [x]	[OK]
Prilagodljiva postavitev	preizkus na več velikostih zaslona	[da]	[OK]
Varovanje uporabniških podatkov	bcrypt, JWT z rokom	[opis]	[OK]
Odzivnost pri zahtevnejših opravilih	asinhrona obdelava	[opis]	[OK]

Meritev odzivnosti vmesnika in endpointov. [Odzivnost uporabniškega vmesnika smo izmerili z orodjem Lighthouse na treh ključnih straneh; ocene za performanco so X, za dostopnost pa X. Latenco glavnih endpointov zalednega sistema smo izmerili z orodjem autocannon: p_{95} je v vseh primerih pod X ms, torej pod zahtevo 300 ms.]

Varnost. Gesla so pred shranjevanjem zgoščena z algoritmom bcrypt (razdelek 4.5.2), žetoni JWT imajo rok veljavnosti 7 dni, poti vmesnika API pa ščiti sredinski preverjevalnik žetonov. **[Orodje npm audit ob zadnjem pregledu ni javilo kritičnih ranljivosti v odvisnostih.]**

5.11 Uporabniški preizkus

Izvedli smo formativni uporabniški preizkus [57] z namenom odkriti težave uporabnosti, ne pa statistično ovrednotiti izdelka.

Udeleženci in postopek. V preizkus smo vključili **[N]** udeležencev iz kroga družine in bližnjih prijateljev, katerih starost in računalniška pismenost sta se med seboj razlikovali (tabela 5.14). Vsak udeleženec je prejel enak seznam nalog: registracija, objava oglasa, všečkanje oglasa, izbira slovenskega jezika v nastavitvah in vrednotenje poljubnega vozila. Med izvajanjem je udeleženec razmišljal na glas, opazovalec pa je beležil, ali je nalogo dokončal samostojno, in vsako opaženo težavo.

Tabela 5.14: Udeleženci uporabniškega preizkusa.

#	Starost (razpon)	Rač. pismenost (1–5)	Naprava
1	[x]	[x]	[x]
2	[x]	[x]	[x]
3	[x]	[x]	[x]
[...]			

Rezultati. Vsi udeleženci so vse naloge dokončali brez pomoči, kar potrjuje, da so glavne poti v vmesniku dovolj jasne (RV4). Kljub temu so odkrili nekaj pomanjkljivosti; tabela 5.15 jih razvršča po resnosti (lestvica 0–4 po Nielsenu [57]) in navaja, ali so bile odpravljene.


Tabela 5.15: Težave, odkrite med uporabniškim preizkusom (resnost po lestvici 0–4).

Težava	Resnost	Status
Premajhni naslovi odstrani v glavi glavne strani	[x]	odpravljeno
Manjkajoče polje za ponovni vnos gesla pri registraciji	[x]	odpravljeno
Velika števila brez ločil za tisočice	[x]	odpravljeno
Manjkajoč opis pod slikami oblik vozil v obrazcu	[x]	odpravljeno
Premalo vozil, dostopnih za vrednotenje	[x]	[v načrtu]

Omejitve preizkusa (majhen in priložnostni vzorec, brez standardiziranega vprašalnika, brez merjenja časa po nalogah) obravnavamo v razdelku 5.13.

5.12 Simulacija uporabe


Za ponazoritev delovanja rešitve povzemamo tipičen potek uporabe. Uporabnik je ob vstopu usmerjen na glavno stran (slika 5.11), kjer sta izpostavljeni prijava in registracija ter pregled novih in vseh objavljenih oglasov. Registriran uporabnik lahko objavi oglas prek vodene forme (slika 5.12), ovrednoti poljubno vozilo, všečka oglase in si ogleda svoj profil z všečkanimi vozili (slika 5.13).



Slika 5.11: Glavna stran prototipa

The screenshot shows the 'Ustvari oglas za avto' (Create car ad) form. The header includes the logo, navigation links, and a user profile for 'Nik Katanovic Leban' with an 'Odjava' (Logout) link. The main content area has a title 'Ustvari oglas za avto' and a subtext: 'Vnesite podatke resnično in izpolnite obrazec. Začnimo!' (Enter the data truthfully and fill out the form. Let's start!). Below this is a progress bar with four steps: 1. Splošne informacije (General information), 2. Tehnične podrobnosti (Technical details), 3. Stanje in oprema (Condition and equipment), and 4. Fotografije in cena (Photos and price). The first step is active. The form fields for 'Splošne informacije' are: 'Znamka' (Brand) with a dropdown menu, 'Model' with a dropdown menu, 'Prva registracija (leto)' (First registration (year)) with a dropdown menu showing '2025', 'Prva registracija (mesec)' (First registration (month)) with a dropdown menu, and 'Prevoženih km' (Mileage) with a text input field showing '0' and a unit 'km'. A 'Naprej' (Next) button is at the bottom right.

Slika 5.12: Vodena forma za objavo oglasa



Slika 5.13: Stran uporabnika s prikazanimi všečkanih vozili

Primerjava ocen z obstoječimi portali. Za ilustracijo smo delovanje sistema primerjali s ponudbo na dveh spletnih portalih na treh vozilih (tabela 5.16). Sistematično in kvantitativno oceno natančnosti podaja razdelek 5.5; ta primerjava je zgolj kvalitativna ponazoritev.

Tabela 5.16: Primerjava ocenjenih cen s ponudbo na spletnih portalih (v evrih).

	Audi A3	BMW ser. 2	Citroën Berlingo
slov. portal (razpon)	4.000–6.000	9.000–12.000	7.500–10.000
nem. portal (razpon)	4.500–9.000	pribl. 11.100	8.000–12.000
Sistem — dobra cena	4.500	7.600	7.600
Sistem — sredinska cena	6.350	9.300	9.941
Sistem — slaba cena	7.600	10.500	12.100
Raznolikost	49 %	31 %	45 %

Pri vozilih z nizko raznolikostjo ponudbe (Audi A3, BMW serije 2) se sredinska ocena dobro ujema s cenami na obeh portalih. Pri modelu Citroën

Berlingo je raznolikost bistveno višja, zato je razpon med dobro in slabo oceno širši, sredinska ocena pa manj zanesljiva — kar je skladno z ugotovitvijo iz razdelka 5.5, da napaka strmo narašča z raznolikostjo ponudbe. Pri interpretaciji je treba upoštevati, da sistem ocenjuje pričakovano prodajno in ne oglaševano ceno.

5.13 Grožnje veljavnosti

Notranja veljavnost. Kot merilo resnice pri merjenju natančnosti uporabljamo *oglaševano* ceno, ne dejanske prodajne cene, ki ni javno dostopna. Namerni popust, s katerim sistem cilja pričakovano prodajno ceno, je zato ocenjen in ne umerjen na dejanskih prodajah. Isti fizični oglas se lahko pojavi pri več virih; prečno preverjanje izloči zapise z istim izvornim oglasom, ne more pa zaznati podvojitve med viri.

Zunanja veljavnost. Podatki pokrivajo 10 znamk in pretežno slovenski trg (z manjšim nemškim vzorcem); znamka z največ oglasi na trgu (okoli 8000 oglasov) v šifrantu ni zajeta in je iz analize izpuščena. Uporabniški preizkus je temeljil na majhnem in priložnostnem vzorcu.

Konstruktna veljavnost. Pojem „tržna vrednost“ operacionaliziramo kot uteženo povprečje oglaševanih cen primerljivih vozil, znižano za pričakovani pogajalski popust; „raznolikost ponudbe“ pa kot relativno širino interkvartilnega razpona teh cen. Drugačna operacionalizacija bi lahko dala drugačne rezultate.

Zanesljivost. Meritve latence in obremenitve so bile izvedene na deljenem produkcijskem strežniku, kjer lahko na rezultate vpliva ozadje. Meritve natančnosti so ponovljive nad fiksnim posnetkom baze.

5.14 Povzetek ugotovitev

Tabela 5.17 povzema odgovore na raziskovalna vprašanja glede na vnaprej postavljena merila.

Tabela 5.17: Povzetek odgovorov na raziskovalna vprašanja.

RV	Glavni rezultat	Sodba
RV1 natančnost	MdAPE 13,5 % (9–10 % za dobro pokrita vozila), bistveno bolje od naivne ocene (37,8 %), primerljivo z drugimi metodami	izpolnjeno
RV2 odvisnost	napaka pada z velikostjo vzorca (ustali se pri $n \approx 20$), narašča s starostjo, kilometrino in raznolikostjo ponudbe (7,5 % do 29,7 %)	pojasnjeno
RV3 hitrost	vrednotenje 2 ms (p50), 13,5 ms (p99); indeks odpravi odvisnost od velikosti baze; [meja X z/s]	[izpolnjeno]
RV4 uporabnost	vse naloge dokončane brez pomoči; [X] težav odpravljenih	izpolnjeno

Sodba o zastavljenih izhodiščih. Rezultati *potrjujejo* izhodišča, ki smo si jih zastavili na začetku. Sistem na podlagi štirih atributov vozila vrne oceno vrednosti z mediano odstotne napake 13,5 % (brez namernega popusta), pri dobro pokritih vozilih pa 9–10 %, kar je znotraj zastavljenega praga 15 % in bistveno bolje od naivne metode. Predlagani pristop se med primerljivo natančnimi metodami ne uvršča na prvo mesto — preprost k -najbližjih sosedov doseže 11,2 % — je pa edini, ki poleg točkovne ocene vrne tudi razložljiv cenovni razpon in indeks zaupanja, ta pa se izkaže za dober pokazatelj dejanske zanesljivosti posamezne ocene. Glavne omejitve so odvisnost od enega prevladujočega podatkovnega vira, nižja natančnost pri starejših

vozilih in modelih z razpršeno ponudbo ter merilo resnice, ki temelji na oglaševanih in ne prodajnih cenah. Konkretni smeri za izboljšave — vključno s preходом na metode strojnega učenja, ki jih ta analiza dodatno utemeljuje — navajamo v poglavju 6.

Poglavje 6

Sklep

Cilj diplomskega dela je bil na podlagi jasnopredeljenih zahtev razviti prototip, ki uporabnikom omogoča objavo in pregled oglasov rabljenih vozil, ter vanjo vgraditi sistem za samodejno ocenjevanje tržne vrednosti vozila na podlagi primerljivih vozil na trgu. Oba cilja sta bila dosežena: delujoč prototip z ločeno odjemalsko in zaledno komponento ter komponento za vrednotenje vozil (poglavje 3), zasnovali pa smo tudi čevovodža zajem, normalizacijo in primerjavo tržnih podatkov po pristopu primerljivih prodaj z uteženim povprečjem (razdelka 4.7.2 in 4.7.4). Prototip je nameščen v produkcijskem okolju in podpira vse zastavljene funkcionalne zahteve, od registracije, prijave ter objave in pregleda oglasov do vsehkanja in vrednotenja poljubnega vozila; izpolnjene so tudi nefunkcionalne zahteve glede odzivnosti vmesnika, varovanja uporabniških podatkov s zgoščevanjem gesel in časovno omejenimi žetoni ter razširljivosti arhitekture z ločenimi komponentami in samodejnimi testi. Podatkovna baza trenutno obsega približno 86.000 normaliziranih oglasov za deset znamk vozil.

Na začetku smo si zastavili, da je mogoče uporabniku na podlagi zbranih tržnih podatkov in primerjave s podobnimi vozili ponuditi uporabno in dovolj natančno oceno tržne vrednosti. Sistem na podlagi znamke, modela, letnika in prevoženih kilometrov vrne oceno cene skupaj z indeksom zaupanja, ki uporabnika pregledno opozori na zanesljivost posamezne ocene glede na veli-

kost vzorca primerljivih vozil. Sistematično prečno preverjanje (razdelek 5.5) je pokazalo mediano absolutne odstotne napake 13,5 %, pri dobro pokritih vozilih pa 9–10 %; ocena je bistveno natančnejša od naivne referenčne metode in znotraj zastavljenega praga 15 %. Napaka strmo narašča z raznolikostjo ponudbe (od 7,5 % pri enotni do 29,7 % pri razpršeni ponudbi), zato indeks zaupanja in prikazani cenovni razpon uporabnika pregledno opozorita na manj zanesljive ocene. Preizkus z uporabniki je potrdil razumljivost in enostavnost uporabniškega vmesnika. Glavne omejitve rešitve so odvisnost od enega prevladujočega podatkovnega vira, nižja zanesljivost ocene pri starejših vozilih in modelih z razpršeno ponudbo ter omejen obseg preizkusa z uporabniki.

- **Razširitev nabora vhodnih spremenljivk.** Ko bo na voljo dovolj normaliziranih podatkov, bi bilo smiselno v algoritem vključiti dodatne parametre, (kot so oprema, vrsta goriva, tip menjalnika in stanje vozila, kar bi izboljšalo natančnost ocene). V prihodnjem se bo z velikostjo uporabnikov, večal tudi moj dostop do podatkov in ne bomo rabili biti odvisni od ostalih virov podatkov.
- **Dinamično prilagajanje intervalov primerljivosti.** Namesto fiksnih mej bi lahko intervale kilometrine in letnika prilagajali sproti glede na gostoto podatkov v posameznem segmentu (na primer širši interval pri redkih modelih in ožji pri pogostih), s čimer bi omilili razmerje med pristranskostjo in varianco.
- **Izboljšanje kakovosti podatkov.** Analiza (razdelek 5.4) je pokazala, da približno 11 % normaliziranih oglasov vsebuje očitno napačne vrednosti, zato bi bilo smiselno v cevovod dodati samodejno filtriranje osamelcev (npr. po interkvartilnem razponu). Dopolniti je treba tudi šifrant znamk in modelov (manjkajoča prevladujoča znamka, združevanje modelov pri nekaterih znamkah).
- **Uvedba metod strojnega učenja.** Analiza natančnosti (razdelek 5.5) je pokazala, da že preprosta metoda k -najbližjih sosedov preseže seda-

nji pristop primerljivih prodaj, kar dodatno utemeljuje ta korak. Ko bo obseg lastnih, normaliziranih podatkov zadosten, bi lahko sedanji, razložljivi pristop dopolnili ali nadomestili z zmogljivejšimi modeli (na primer regresijskimi modeli, naključnimi gozdovi ali nevronskimi mrežami), ki bi lahko predstavili bolj zahtevne, nelinearne odvisnosti med lastnostmi vozila in ceno [26].

- **Zmanjšanje odvisnosti od zunanjih virov.** Z rastjo števila uporabnikov in oglasov, na platformi, bomo lahko delež zunanjih podatkov postopno zmanjševali in ocene vse bolj gradili na podatkih, ki so zbrani znotraj same aplikacije. To bo izboljšalo tako natančnost kot vzdržnost sistema, saj se s tem zmanjša odvisnost od krhkih postopkov zajema s spletnih strani.
- **Postopna migracija zalednega sistema na TypeScript.** Uvedba statičnega preverjanja tipov bi dolgoročno izboljšala zanesljivost in vzdržljivost zalednega dela aplikacije [24].
- **Nadgradnja infrastrukture in spremljanja delovanja.** Smiselna nadaljnja koraka sta uvedba centraliziranega beleženja dogodkov in spremljanja delovanja sistema (angl. *monitoring*) v produkcijskem okolju. To bi olajšalo odkrivanje napak in analizo obremenitve sistema, ter razširitev nabora avtomatiziranih testov na del aplikacije za vrednotenje vozil in odjemalski del, ki v tem trenutku nista pokrita enako temeljito kot zaledni sistem, za katerega teste ob vsakem zahtevku za združitev že izvaja orodje GitHub Actions.

Literatura

Članki v revijah

- [1] N. S. Altman. „An Introduction to Kernel and Nearest-Neighbor Non-parametric Regression“. V: *The American Statistician* 46.3 (1992), str. 175–185. DOI: 10.1080/00031305.1992.10475879.
- [14] Irfan Darmawan in sod. „Evaluating Web Scraping Performance Using XPath, CSS Selector, Regular Expression, and HTML DOM With Multiprocessing Technical Applications“. V: *JOIV: International Journal on Informatics Visualization* (2022). DOI: 10.30630/joiv.6.4.1525.
- [30] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt in sod. „Array programming with NumPy“. V: *Nature* 585 (2020), str. 357–362. DOI: 10.1038/s41586-020-2649-2.
- [34] John D. Hunter. „Matplotlib: A 2D graphics environment“. V: *Computing in Science & Engineering* 9.3 (2007), str. 90–95. DOI: 10.1109/MCSE.2007.55.
- [35] Rob J. Hyndman in Anne B. Koehler. „Another look at measures of forecast accuracy“. V: *International Journal of Forecasting* 22.4 (2006), str. 679–688. DOI: 10.1016/j.ijforecast.2006.03.001.
- [39] Marijn Janssen, Yannis Charalabidis in Anneke Zuiderwijk. „Benefits, Adoption Barriers and Myths of Open Data and Open Government“. V: *Information Systems Management* 29.4 (2012), str. 258–268. DOI: 10.1080/10580530.2012.716740.

-
- [47] Alberto H. F. Laender in sod. „A Brief Survey of Web Data Extraction Tools“. V: *ACM SIGMOD Record* 31.2 (2002), str. 84–93. DOI: 10.1145/565117.565137.
- [48] John D. C. Little. „A Proof for the Queuing Formula: $L = \lambda W$ “. V: *Operations Research* 9.3 (1961), str. 383–387. DOI: 10.1287/opre.9.3.383.
- [56] Gonzalo Navarro. „A Guided Tour to Approximate String Matching“. V: *ACM Computing Surveys* 33.1 (2001), str. 31–88. DOI: 10.1145/375360.375365.
- [58] Christopher Olston in Marc Najork. „Web Crawling“. V: *Foundations and Trends in Information Retrieval* 4.3 (2010), str. 175–246. DOI: 10.1561/15000000017.
- [62] David L. Parnas. „On the Criteria To Be Used in Decomposing Systems into Modules“. V: *Communications of the ACM* 15.12 (1972), str. 1053–1058. DOI: 10.1145/361598.361623. URL: <https://doi.org/10.1145/361598.361623>.

Članki v zbornikih konferenc

- [24] Zheng Gao, Christian Bird in Earl T. Barr. „To Type or Not to Type: Quantifying Detectable Bugs in JavaScript“. V: *Proceedings of the 39th International Conference on Software Engineering (ICSE)*. IEEE Press, 2017, str. 758–769. DOI: 10.1109/ICSE.2017.75.
- [26] Enis Gegic in sod. „Car Price Prediction using Machine Learning Techniques“. V: *TEM Journal*. Zv. 8. 1. 2019, str. 113–118. DOI: 10.18421/TEM81-16.
- [64] Niels Provos in David Mazières. „A Future-Adaptable Password Scheme“. V: *Proceedings of the FREENIX Track: 1999 USENIX Annual Technical Conference*. 1999, str. 81–91.

Ostala literatura

- [2] Auto Trader Group. *Auto Trader – New and used cars for sale*. Dostopano: 2. 9. 2026. 2026. URL: <https://www.autotrader.co.uk>.
- [3] AutoScout24. *AutoScout24 – Nova in rabljena vozila*. Dostopano: 22. 8. 2026. 2026. URL: <https://www.autoscout24.com>.
- [4] AvtoNet. *AvtoNet – Oglasnik rabljenih in novih vozil*. Dostopano: 22. 8. 2026. 2026. URL: <https://www.avto.net>.
- [5] Axios Contributors. *Axios – Promise based HTTP client for the browser and node.js*. <https://axios.rest>. Uradna dokumentacija knjižnice. 2024.
- [6] Michael Bayer. *Alembic Documentation*. Dostopano: 2026-07-26. 2024. URL: <https://alembic.sqlalchemy.org/>.
- [7] Stefan Behnel, Martijn Faassen in Ian Bicking. *lxml – XML and HTML with Python*. <https://lxml.de>. Uradna dokumentacija. 2024.
- [8] Philip R. Bevington in D. Keith Robinson. *Data Reduction and Error Analysis for the Physical Sciences*. 3. izd. New York, NY: McGraw-Hill, 2003. ISBN: 9780072472271.
- [9] CARFAX. *CARFAX – Vehicle History Reports and Car Values*. Dostopano: 22. 8. 2026. 2026. URL: <https://www.carfax.com>.
- [10] Cars.com. *Cars.com – New and used cars for sale, prices and values*. Dostopano: 2. 9. 2026. 2026. URL: <https://www.cars.com>.
- [11] BullMQ Contributors. *BullMQ Documentation*. Dostopano: junij 2024. 2024. URL: <https://docs.bullmq.io/>.
- [12] Express.js Contributors. *Express.js Documentation*. Dostopano: junij 2024. 2024. URL: <https://expressjs.com/>.
- [13] Sequelize Contributors. *Sequelize Documentation*. Dostopano: junij 2024. 2024. URL: <https://sequelize.org/>.

- [15] Edsger W. Dijkstra. „On the Role of Scientific Thought“. V: *Selected Writings on Computing: A Personal Perspective*. New York, NY: Springer-Verlag, 1982, str. 60–66. DOI: 10.1007/978-1-4612-5695-3_12.
- [16] Docker, Inc. *Docker – Accelerated, Containerized Application Development*. <https://www.docker.com>. Uradna dokumentacija. 2024.
- [17] Docker, Inc. *Docker Compose Overview*. <https://docs.docker.com/compose/>. Uradna dokumentacija. 2024.
- [18] Dokploy. *Dokploy Documentation*. <https://docs.dokploy.com>. Uradna dokumentacija. 2024.
- [19] Ramez Elmasri in Shamkant B. Navathe. *Fundamentals of Database Systems*. 7. izd. Pearson, 2015. ISBN: 9780133970777.
- [20] Eurostat. *Eurostat – European Statistics*. Dostopano: junij 2025. 2024. URL: <https://ec.europa.eu/eurostat>.
- [21] Eurotax. *Eurotax*. Dostopano: 20. 8. 2026. 2026. URL: <https://www.eurotax.si>.
- [22] David Flanagan. *JavaScript: The Definitive Guide*. 7. izd. O'Reilly Media, 2020. ISBN: 9781491952023.
- [23] Martin Fowler. *Continuous Integration*. <https://martinfowler.com/articles/continuousIntegration.html>. Dostopano: 2026-08-01. 2006.
- [25] Hector Garcia-Molina, Jeffrey D. Ullman in Jennifer Widom. *Database Systems: The Complete Book*. 2. izd. Pearson, 2008, str. 587–625. ISBN: 9780131873254.
- [27] GitHub, Inc. *GitHub Actions Documentation*. <https://docs.github.com/en/actions>. Uradna dokumentacija. 2024.
- [28] Google. *The Go Programming Language*. <https://go.dev>. Uradna dokumentacija. 2024.

- [29] Dick Hardt. *The OAuth 2.0 Authorization Framework*. RFC 6749, Internet Engineering Task Force (IETF). Okt. 2012. DOI: 10.17487/RFC6749. URL: <https://www.rfc-editor.org/rfc/rfc6749>.
- [31] Trevor Hastie, Robert Tibshirani in Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2. izd. New York, NY: Springer, 2009. ISBN: 9780387848570. DOI: 10.1007/978-0-387-84858-7.
- [32] Hetzner Online GmbH. *Hetzner Cloud*. <https://www.hetzner.com/cloud>. Uradna spletna stran. 2024.
- [33] Jez Humble in David Farley. *Continuous Delivery: Reliable Software Releases through Build, Test, and Deployment Automation*. Boston, MA: Addison-Wesley, 2010. ISBN: 9780321601919.
- [36] Appraisal Institute. *The Appraisal of Real Estate*. 15. izd. Chicago, IL: Appraisal Institute, 2020. ISBN: 9781935328780.
- [37] ISO. *ISO 3779:2009 – Road vehicles – Vehicle identification number (VIN) – Content and structure*. <https://www.iso.org/standard/52200.html>. Mednarodni standard za zgradbo identifikacijske številke vozila (VIN). 2009.
- [38] ISO/IEC. *ISO/IEC 14882:2020 – Programming languages – C++*. <https://www.iso.org/standard/79358.html>. Mednarodni standard programskega jezika C++. 2020.
- [40] Michael B. Jones, John Bradley in Nat Sakimura. *JSON Web Token (JWT)*. RFC 7519, Internet Engineering Task Force (IETF). Maj 2015. DOI: 10.17487/RFC7519. URL: <https://www.rfc-editor.org/rfc/rfc7519>.
- [41] Kelley Blue Book. *Kelley Blue Book – New and used car price values*. Dostopano: 2. 9. 2026. 2026. URL: <https://www.kbb.com>.

- [42] Gene Kim in sod. *The DevOps Handbook: How to Create World-Class Agility, Reliability, and Security in Technology Organizations*. 2. izd. Portland, OR: IT Revolution Press, 2021. ISBN: 9781950508402.
- [43] Martin Kleppmann. *Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems*. 1. izd. O'Reilly Media, 2017. ISBN: 978-1449373320.
- [44] Philip Kotler in Kevin Lane Keller. *Marketing Management*. 15. izd. Harlow: Pearson Education, 2016. ISBN: 9781292092621.
- [45] La Centrale. *La Centrale – Annonces de voitures d’occasion et cote auto*. Dostopano: 2. 9. 2026. 2026. URL: <https://www.lacentrale.fr>.
- [46] Ladjs Contributors. *SuperTest – Super-agent driven library for testing HTTP servers*. <https://github.com/ladjs/supertest>. Uradna dokumentacija. 2024.
- [49] MailHog. *MailHog*. <https://github.com/mailhog/MailHog>. Uradno programsko skladišče. 2024.
- [50] Meta Open Source. *Jest – Delightful JavaScript Testing*. <https://jestjs.io/>. Uradna dokumentacija. 2024.
- [51] Meta Platforms, Inc. *React – The library for web and native user interfaces*. <https://react.dev>. Uradna dokumentacija. 2024.
- [52] Microsoft. *Playwright – Fast and Reliable End-to-End Testing for Modern Web Apps*. <https://playwright.dev>. Uradna dokumentacija. 2024.
- [53] Microsoft. *TypeScript: JavaScript With Syntax For Types*. Dostopano: junij 2025. 2024. URL: <https://www.typescriptlang.org/>.
- [54] mobile.de. *mobile.de – Gebrauchtwagen und Neuwagen kaufen*. Dostopano: 22. 8. 2026. 2026. URL: <https://www.mobile.de>.
- [55] Mozilla Developer Network. *JavaScript modules*. <https://developer.mozilla.org/en-US/docs/Web/JavaScript/Guide/Modules>. Tehnična dokumentacija. 2024.

-
- [57] Jakob Nielsen. *Usability Engineering*. San Francisco: Morgan Kaufmann, 1994. ISBN: 9780125184069.
 - [59] OpenJS Foundation. *Node.js – JavaScript runtime built on Chrome’s V8 engine*. <https://nodejs.org>. Uradna dokumentacija. 2024.
 - [60] Orgesleka. *Used Cars Database – eBay Kleinanzeigen*. Dostopano: junij 2025. 2016. URL: <https://www.kaggle.com/datasets/orgesleka/used-cars-database>.
 - [61] OTOMOTO. *OTOMOTO – Ogłoszenia motoryzacyjne*. Dostopano: 2. 9. 2026. 2026. URL: <https://www.otomoto.pl>.
 - [63] pmndrs. *Zustand – Getting Started*. <https://docs.pmnd.rs/zustand/getting-started/introduction>. Uradna dokumentacija. 2024.
 - [65] Python Software Foundation. *Python 3.11 – What’s New In Python 3.11*. <https://docs.python.org/3/whatsnew/3.11.html>. Uradna dokumentacija. 2022.
 - [66] Sebastián Ramírez. *FastAPI Documentation*. Dostopano: 2026-07-26. 2024. URL: <https://fastapi.tiangolo.com/>.
 - [67] RapidFuzz Contributors. *RapidFuzz Documentation*. <https://rapidfuzz.github.io/RapidFuzz/>. Uradna dokumentacija. 2024.
 - [68] React Hook Form Contributors. *React Hook Form – Performant, flexible and extensible forms*. <https://react-hook-form.com/>. Uradna dokumentacija. 2024.
 - [69] Redis Ltd. *Redis Documentation*. Dostopano: junij 2024. 2024. URL: <https://redis.io/docs/latest/>.
 - [70] Redux Contributors. *Redux – A JS library for predictable and maintainable global state*. <https://redux.js.org>. Uradna dokumentacija. 2024.
 - [71] Leonard Richardson. *Beautiful Soup Documentation*. <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>. Uradna dokumentacija. 2024.

- [72] Selenium Project. *Selenium WebDriver Documentation*. <https://www.selenium.dev/documentation/webdriver/>. Uradna dokumentacija. 2024.
- [73] Yaron Sheffer, Dick Hardt in Michael B. Jones. *JSON Web Token Best Current Practices*. Dostopano: junij 2024. 2020. DOI: 10.17487/RFC8725. URL: <https://www.rfc-editor.org/rfc/rfc8725>.
- [74] Statistični urad Republike Slovenije. *Statistični urad Republike Slovenije – SURS*. Dostopano: junij 2025. 2024. URL: <https://www.stat.si/StatWeb/>.
- [75] TanStack. *TanStack Query – Powerful asynchronous state management*. <https://tanstack.com/query/latest>. Uradna dokumentacija. 2024.
- [76] The Linux man-pages project. *crontab(5) — Linux manual page*. Dostopano: 2026-07-26. 2023. URL: <https://man7.org/linux/man-pages/man5/crontab.5.html>.
- [77] The PostgreSQL Global Development Group. *PostgreSQL Documentation: What Is PostgreSQL?* Dostopano: 21. 6. 2026. 2025. URL: <https://www.postgresql.org/docs/current/intro-what-is.html>.
- [78] Mark Tungate. *Adland: A Global History of Advertising*. London: Kogan Page, 2007. ISBN: 9780749448370.
- [79] Vite Contributors. *Vite – Next Generation Frontend Tooling*. <https://vite.dev>. Uradna dokumentacija orodja. 2024.
- [80] Evan Wallace. *esbuild – An extremely fast bundler for the web*. <https://esbuild.github.io>. Uradna dokumentacija orodja. 2024.
- [81] Webpack Contributors. *webpack – Module Bundler*. <https://webpack.js.org>. Uradna dokumentacija. 2024.
- [82] WHATWG. *HTML Living Standard – Web Storage*. <https://html.spec.whatwg.org/multipage/webstorage.html>. Uradna specifikacija. 2024.

- [83] Adam Wiggins. *The Twelve-Factor App*. Dostopano: 2026-08-01. 2017.
URL: <https://12factor.net/>.
- [84] Adam Wiggins. *The Twelve-Factor App – XI. Logs*. Dostopano: 22. 8. 2026. 2017. URL: <https://12factor.net/logs>.

Dodatek

Koda: Definicija modela User

Izsek kode 10: Definicija modela User z ORM knjižnico Sequelize.

```
1 import { DataTypes } from "sequelize";
2 import sequelize from "../config/db.js";
3
4 const User = sequelize.define(
5   "User",
6   {
7     id: {
8       type: DataTypes.INTEGER,
9       autoIncrement: true,
10      primaryKey: true,
11    },
12    firstName: {
13      type: DataTypes.STRING,
14      allowNull: false,
15    },
16    lastName: {
17      type: DataTypes.STRING,
18    },
19    email: {
20      type: DataTypes.STRING,
21      allowNull: false,
22      unique: true,
23      validate: {
24        isEmail: true,
25      },
26    },
27    telephone: {
28      type: DataTypes.STRING,
```

```
29     allowNull: false,
30   },
31   password: {
32     type: DataTypes.STRING,
33     allowNull: false,
34   },
35   soldCars: {
36     type: DataTypes.INTEGER,
37     defaultValue: 0,
38   },
39 },
40 { timestamps: true },
41 );
42
43 export default User;
```

Izsek kode 11: Primer normalizacije podatkov

```
1 def extract_data_from_raw_payload(raw
2   valid = True
3   data = {}
4
5   raw_brand = raw_payload.get("brand", None)
6   raw_model = raw_payload.get("model", None)
7
8   if not raw_brand:
9     valid = False
10  if not raw_model:
11    valid = False
12
13  if valid:
14    brand_match = match_brand(_preprocess(raw_brand), SOURCE)
15    if brand_match is None:
16      print(f"Could not match brand '{raw_brand}' for raw_id:
17        ↳ {id}")
18      valid = False
19    else:
20      brand_id, brand_canonical = brand_match
21      data["brand_name"] = brand
22
23      model_match = match_model
24      _preprocess(raw_model), brand_id, brand_canonical, SOURCE
```

```
24         )
25         if model_match is None:
26             print(
27                 f"Could not match model '{raw_model}' (brand:
                ↪ '{brand_canonical}') for raw_id: {id}"
28             )
29             valid = False
30         else:
31             _, model_canonical = model_match
32             data["model_name"] =
```
